3 Forschungsdesign und Methodik

3.1 Design Science Research als Forschungsrahmen

Die Forschung in der Wirtschaftsinformatik wird durch zwei komplementäre Paradigmen geprägt: die verhaltenswissenschaftliche Forschung (*Behavioral Science*) und die gestaltungsorientierte Forschung (*Design Science*) (Hevner et al., 2004, S. 75). Während das verhaltenswissenschaftliche Paradigma auf die Entwicklung und empirische Überprüfung von Theorien abzielt, die menschliches oder organisationales Verhalten erklären oder vorhersagen, verfolgt Design Science Research (DSR) das Ziel, die Grenzen menschlicher und organisationaler Leistungsfähigkeit durch die Schaffung innovativer Artefakte zu erweitern (Hevner et al., 2004, S. 75).

Das Erkenntnisziel dieser beiden Paradigmen unterscheidet sich fundamental: Behavioral Science strebt nach Wahrheit (*truth*), Design Science nach Nützlichkeit (*utility*) (Hevner et al., 2004, S. 76). Diese Unterscheidung ist für die vorliegende Arbeit entscheidend, da das identifizierte Forschungsproblem – die fehlende technische Operationalisierung regulatorischer, technischer und strategischer Anforderungen in GenAI-Systemen – nicht primär durch die Überprüfung bestehender Theorien, sondern durch die Konstruktion eines neuartigen Artefakts adressiert wird. Die drei Problemdimensionen (PD1: Fragmentierung bestehender Ansätze, PD2: Inadäquanz konventioneller QA-Mechanismen für generative KI, PD3: Operationalisierungslücke zwischen regulatorischen Anforderungen und technischer Umsetzung) konstituieren ein Gestaltungsproblem, das nach dem DSR-Paradigma bearbeitet wird.

Hevner et al. (2004, S. 77) definieren IT-Artefakte als Konstrukte (Vokabular und Symbole), Modelle (Abstraktionen und Repräsentationen), Methoden (Algorithmen und Praktiken) sowie Instanziierungen (implementierte und prototypische Systeme). Das in dieser Arbeit entwickelte Artefakt – eine Referenzarchitektur für GenAIOps mit integriertem Quality-Gate-Kontrollsystem – vereint mehrere dieser Artefakttypen: Es umfasst ein Modell (die architekturelle Struktur), eine Methode (die Gate-Systematik mit Traceability-Mechanismen) und eine Instanziierung (den Azure-basierten Proof of Concept). Diese Mehrfachklassifikation spiegelt die Komplexität des Forschungsgegenstands wider und entspricht der von Hevner et al. (2004, S. 78)

beschriebenen Praxis, dass DSR-Artefakte häufig Elemente verschiedener Typen integrieren.

Die Wahl von DSR als Forschungsparadigma wird durch den Charakter des Forschungsbeitrags zusätzlich gestützt. Die vorliegende Arbeit zielt nicht auf eine radikale Neuerfindung, sondern auf eine formalisierte Integration: Bestehende Mechanismen aus den Domänen LLMOps, Policy-as-Code und Compliance-Management werden rekonfiguriert, formalisiert und für den spezifischen Kontext hochriskanter generativer KI-Systeme kontextualisiert. Dieser Beitragstypus entspricht dem von Hevner et al. (2004, S. 80) beschriebenen Zusammenspiel von Relevanz- und Rigor-Zyklus, in dem Wissen aus der Wissensbasis (*knowledge base*) auf ein relevantes Praxisproblem angewendet wird.

Zur Sicherstellung methodischer Qualität formulieren Hevner et al. (2004, S. 83) sieben Richtlinien für Design Science Research. Tabelle 1 zeigt die Richtlinien und ihre konkrete Umsetzung in dieser Arbeit.

Tabelle 1: Hevner-Richtlinien und ihre Umsetzung in dieser Arbeit (nach Hevner et al., 2004, S. 83)

Richtlinie	Beschreibung	Umsetzung in dieser Arbeit
G1: Design as an Artifact	DSR muss ein tragfähiges Artefakt hervorbringen	Referenzarchitektur (Primärartefakt) mit integriertem Quality-Gate-Kontrollsystem; Azure PoC als Instanziierung
G2: Problem Relevance	Lösung eines relevanten Geschäftsproblems	PD1–PD3: Governance-Lücke bei GenAI-Operationalisierung (Kap. 1, 4)
G3: Design Evaluation	Rigorose Evaluation von Nutzen und Qualität	Dreistufig: Coverage-Matrix, PoC-Walkthrough, Expert-Reviews (Kap. 6)
G4: Research Contributions	Klarer Beitrag zu Artefakt, Foundations oder Methodologie	Formalisierte Integration: Rekonfiguration + Formalisierung + Kontextualisierung (Kap. 7)
G5: Research Rigor	Rigorose Konstruktions- und Evaluationsmethoden	Kombination Hevner/Peffers/vom Brocke + Expert-Reviews (n ≥ 4)
G6: Design as a Search Process	Iterative Suche nach effektiven Artefakten	Zwei Iterationen: Iter. 1 Konzept → Iter. 2 PoC + Refinement (Kap. 5)

G7: Communication of Research	Zielgruppengerechte Kommunikation	Architektur generisch (Management), PoC technisch (Entwicklung) (Kap. 7–8)

3.2 Methodischer Rahmen und Vorgehensmodell

Der methodische Rahmen dieser Arbeit integriert drei etablierte DSR-Frameworks auf komplementären Abstraktionsebenen: Hevner et al. (2004) auf der Meta-Ebene als Qualitätsrahmen, Peffers et al. (2007) auf der Prozessebene als strukturgebendes Vorgehensmodell sowie vom Brocke und Maedche (2019) als Planungs- und Kommunikationsinstrument. Diese Kombination verbindet die Stärken der einzelnen Ansätze: die kontextgebundene Theorieanbindung Hevners mit der prozessualen Konkretheit von Peffers und der strukturierten Projektkommunikation des DSR Grid.

3.2.1 Hevner-Zyklen als Qualitätsrahmen

Hevner et al. (2004, S. 80) modellieren DSR als Zusammenspiel dreier Zyklen: Der *Relevance Cycle* verbindet die Forschung mit dem Anwendungskontext (*environment*) und stellt sicher, dass das Artefakt ein relevantes Praxisproblem adressiert. Der *Rigor Cycle* verankert die Forschung in der Wissensbasis (*knowledge base*) und gewährleistet den Rückgriff auf bestehende Theorien, Methoden und Erkenntnisse. Der *Design Cycle* beschreibt den iterativen Kern der Artefaktkonstruktion und -evaluation.

In der vorliegenden Arbeit manifestiert sich der Relevance Cycle in der Anforderungserhebung (Kap. 4), die regulatorischen, technischen und strategischen Anforderungen — unter besonderer Berücksichtigung des EU AI Act (VO 2024/1689) — aus regulatorischen Primärquellen, normativen Rahmenwerken und der Fachliteratur systematisch in einen Anforderungskatalog überführt. Der Rigor Cycle wird durch die Wissensbasis (vgl. Abschnitt 3.2.3) gespeist, die acht Domänen umfasst. Der Design Cycle wird in zwei Iterationen durchlaufen (vgl. Abschnitt 3.3).

3.2.2 DSRM nach Peffers als Vorgehensmodell

Peffers et al. (2007, S. 52–56) schlagen ein nominales Prozessmodell für DSR vor, das sechs Aktivitäten umfasst: (1) Problemidentifikation und Motivation, (2) Definition der Lösungsziele, (3) Entwurf und Entwicklung, (4) Demonstration, (5) Evaluation und (6) Kommunikation. Dieses Modell dient in der vorliegenden Arbeit als

strukturgebendes Vorgehensmodell, das den Forschungsprozess in nachvollziehbare Schritte gliedert.
Der Einstiegspunkt (*entry point*) in den DSRM-Prozess ist problemzentriert (*problem-centered initiation*), da die Forschung von einer identifizierten Governance-Lücke bei der Operationalisierung regulatorischer, technischer und strategischer Anforderungen in GenAI-Systemen ausgeht (Peffers et al., 2007, S. 56). Dieser Einstiegspunkt ist charakteristisch für Forschung, die auf eine konkrete Praxislücke reagiert und diese durch Artefaktkonstruktion zu schließen sucht.

3.2.3 DSR Grid als Planungsinstrument

Vom Brocke und Maedche (2019, S. 379) führen das DSR Grid als Instrument zur systematischen Planung und Kommunikation von DSR-Projekten ein. Das Grid umfasst sechs Kerndimensionen, die sich aus der Kreuzung von drei Bereichen (Problem, Lösung, Evaluation) mit zwei Perspektiven (Relevanz, Rigor) ergeben (vom Brocke & Maedche, 2019, S. 380). Es unterstützt Forschende dabei, sowohl die praktische Relevanz als auch die wissenschaftliche Rigorosität ihres Projekts systematisch zu reflektieren und zu kommunizieren.
Die konkrete Belegung des DSR Grid für die vorliegende Arbeit wird in Abschnitt 3.3 im Rahmen der Operationalisierung des DSR-Prozesses dargestellt.

3.3 Operationalisierung des DSR-Prozesses

Die Operationalisierung des DSR-Prozesses erfolgt durch das Mapping der sechs DSRM-Aktivitäten auf die Kapitelstruktur dieser Arbeit. Tabelle 2 zeigt die Zuordnung der DSRM-Schritte zu Forschungsfragen, Hevner-Zyklen und den jeweiligen Kapiteln.

Tabelle 2: Mapping der DSRM-Aktivitäten auf die Kapitelstruktur

DSRM-Schritt	Hevner-Cycle	RQ	Kapitel	Artefakt/Output
1 Problem ID	—	—	1 + 3.1	PD1–PD3
2 Objectives	—	—	3.2 + 3.3	Artefaktdefinition, Scope
3 Design & Dev.	Design + Relevance	RQ1, RQ2	4, 5	R-Katalog, Referenzarchitektur mit QG-Kontrollsystem
4 Demonstration	Design (Iter. 2)	RQ2	5.x	Azure-PoC-Instanziierung

5 Evaluation	Rigor	RQ3	6	Coverage, PoC-Walkthrough, Expert-Reviews
6 Communication	—	—	7, 8	Diskussion, Fazit

Der Forschungsprozess folgt einer zweistufigen Iterationslogik: In der ersten Iteration wird das konzeptuelle Artefakt – die Referenzarchitektur mit ihren Design-Prinzipien und der Gate-Systematik – auf Basis der erhobenen Anforderungen entworfen. In der zweiten Iteration wird das Konzept durch einen Azure-basierten Proof of Concept instanziiert und auf Basis der Evaluationsergebnisse verfeinert. Diese Iterationslogik entspricht dem von Hevner et al. (2004, S. 78) beschriebenen Design Cycle, in dem Artefakte in Schleifen aus Konstruktion und Evaluation weiterentwickelt werden.
Tabelle 3 zeigt die Belegung des DSR Grid nach vom Brocke und Maedche (2019) für die vorliegende Arbeit.

Tabelle 3: DSR Grid der vorliegenden Arbeit (nach vom Brocke & Maedche, 2019)

Dimension	Relevanz	Rigor
Problem	PD1–PD3; Stakeholder: CISO, Compliance Officers, LLMOps Engineers, Enterprise Architects	LLMOps-Literatur ohne Gate-Systematik; AI Act ohne technische Operationalisierung; NIST AI RMF ohne CI/CD-Operationalisierung
Lösung	Referenzarchitektur (Primärartefakt) mit deployment-integriertem QG-Kontrollsystem als zentralem Designprinzip; präventiv, detektiv, evidenzbasiert	DP1–DP5 aus Anforderungskatalog abgeleitet; Kernel Theories: Policy-as-Code, Compliance-as-Code, NIST AI RMF (GOVERN-Funktionsbereich); Referenzarchitekturtheorie
Evaluation	Dreistufig: Coverage-Matrix, PoC-Walkthrough, Expert-Reviews (n ≥ 4); 2 Iterationen; Demo-Domäne Healthcare	Triangulation: Coverage = Vollständigkeit, PoC = Machbarkeit, Expert-Reviews = Praxistauglichkeit

3.4 Artefaktdefinition, Scope und Abgrenzung

Das Primärartefakt dieser Arbeit ist eine compliance-orientierte Referenzarchitektur für GenAIOps mit integrierter Quality-Gate-Systematik und Traceability-

Mechanismen, instanziiert durch einen Cloud-Native Proof of Concept zur Operationalisierung regulatorischer Anforderungen. Die Referenzarchitektur bildet das architekturdominante Gesamtartefakt; das lifecycle-integrierte Quality-Gate-Kontrollsystem fungiert als zentrales Designprinzip, das die Architektur durchdringt und ihr die spezifische Compliance-Orientierung verleiht.
Das Kontrollsystem weist drei Charakteristika auf: Es agiert *präventiv* durch Gate-Prüfungen vor dem Deployment, *detektiv* durch Monitoring-Gates in der Produktionsphase und *evidenzbasiert* durch einen durchgehenden Audit Trail mit unveränderlichen Nachweisartefakten. Diese Dreifachcharakteristik operationalisiert den Grundsatz der Verantwortungsnachweisbarkeit (*Accountability-by-Design*) über den Deployment- und Inference-Zyklus.

3.4.1 Architekturelle Struktur

Die Referenzarchitektur gliedert sich in vier Säulen, die gemeinsam den Lösungsraum aufspannen. Tabelle 4 zeigt die generische Architektur und ihre technologische Instanziierung im PoC.

Tabelle 4: Vier Säulen der Referenzarchitektur

Säule	Inhalt	Generisch	PoC (Azure)
S1	Architekturelle Struktur (Schichten/Module)	Container Orchestrator, IaC	AKS, Terraform/Bicep, Helm
S2	Quality-Gate-Kontrollsystem	Policy Engine + GenAI-Eval	OPA/Rego, DeepEval, Azure AI Eval SDK
S3	Pipeline-Integration	CI/CD, GitOps, Signierung	GitHub Actions, ArgoCD, Sigstore/Cosign
S4	Evidence-/Audit-Logik	Policy Engine + Evidence Store	OPA/Rego, Azure Blob (immutable), Azure Monitor

3.4.2 Design-Prinzipien

Die Gestaltung des Artefakts wird durch fünf Design-Prinzipien geleitet, die aus dem Anforderungskatalog (Kap. 4) abgeleitet und durch die Wissensbasis fundiert werden. Die Design-Prinzipien operationalisieren die Verbindung zwischen den erhobenen Anforderungen und der technischen Architekturgestaltung.

Tabelle 5: Design-Prinzipien des Artefakts

DP	Prinzip	Beschreibung
DP1	Compliance als kontrollierbarer Lifecycle-Prozess	Compliance wird nicht nachträglich dokumentiert, sondern als Gate-basierter Kontrollprozess über den Deployment- und Inference-Zyklus operationalisiert
DP2	Anforderungen → Policies → Evidenz (Traceability-Kette)	Jede High-Risk-Anforderung wird in eine Policy (übersetzt in PaC oder kontrollierbare Regel), die automatisch oder manuell Evidenz erzeugt, die auditierbar verknüpft ist
DP3	Gate-Template als Standardisierungseinheit	Einheitliches Gate-Template (Trigger, Evidence, Policy, Decision, Owner, Audit Trail, Waiver) stellt Konsistenz, Auditierbarkeit und Wiederverwendbarkeit sicher
DP4	Trennung von Governance-Ebenen, integrierte Entscheidung	Strategische, technische und Compliance-Gates werden getrennt modelliert, aber über gemeinsame Artefakte und Entscheidungslogik gekoppelt
DP5	Cloud-native Integierbarkeit	Das Kontrollsystem muss in bestehende cloud-native CI/CD/CT-Toolchains integrierbar sein, ohne proprietäre Abhängigkeiten zu erzeugen

3.4.3 Scope und Abgrenzung

Der Scope der Arbeit ist auf hochriskante GenAI-Systeme im Sinne des EU AI Act (Verordnung 2024/1689, Anhang III) begrenzt. Die Referenzarchitektur wird generisch konzipiert, um domänenübergreifend anwendbar zu sein; die Instanziierung im Proof of Concept erfolgt exemplarisch in der Domäne Healthcare (Healthcare als exemplarischer Anwendungsfall für die PoC-Validierung, nicht als Architektur-Scope). Diese Trennung zwischen generischem Architekturdesign und domänenspezifischer Instanziierung entspricht der von Hevner et al. (2004, S. 83, G7) geforderten zielgruppengerechten Kommunikation.

Die Arbeit grenzt sich explizit von einer Produktentwicklung ab. Das Artefakt ist eine Referenzarchitektur im Sinne der Forschung – eine abstrahierte, wiederverwendbare Architekturvorlage mit definiertem Abstraktionsgrad –, kein marktreifes Produkt. Der Proof of Concept dient ausschließlich der Demonstration der technischen Machbarkeit (DSRM-Schritt 4) und der Evaluation (DSRM-Schritt 5), nicht der Produktivstellung.

Explizit außerhalb des Scope liegen: LLM-Training und Fine-Tuning, eigenständige Modellentwicklung (Data Science) sowie die Optimierung von Data-Engineering-Pipelines. Die Architektur fokussiert auf den Deployment- und Inference-Zyklus, d. h. auf die Phase vom fertig trainierten Modell bis zur überwachten Produktionsfreigabe. Der PoC demonstriert einen einzelnen, repräsentativen Deployment-Pfad (Model Registry → Pre-Deployment Gate → Staging → Post-Deployment Gate → Production) und deckt damit mindestens je ein Quality Gate der Dimensionen Compliance, Strategie und Technik ab.

3.4.4 Artefaktidentität und -klassifikation

Das Primärartefakt dieser Arbeit ist eine generische, cloud-native Referenzarchitektur für GenAIOps, deren konstitutives Designprinzip ein lifecycle-integriertes Quality-Gate-Kontrollsystem zur Operationalisierung regulatorischer Anforderungen darstellt. In Übereinstimmung mit der Artefaktklassifikation nach Alan R. Hevner vereint das entwickelte Artefakt mehrere Artefakttypen:

(1) ein **Modell** in Form einer abstrahierten Referenzarchitektur,
(2) eine **Methode** in Form einer formalisierten Gate-Systematik mit Traceability-Logik sowie
(3) eine **Instanziierung** im Rahmen eines Azure-basierten Proof of Concept.

Die Referenzarchitektur bildet dabei das dominierende Designobjekt (Primärartefakt). Das Quality-Gate-Kontrollsystem ist nicht als additiver Bestandteil zu verstehen, sondern als architekturkonstitutives Designprinzip, das die Struktur des Artefakts durchdringt und dessen Compliance-Orientierung bestimmt. Die technische Implementierung im Azure-Stack dient ausschließlich der Demonstration und Evaluation (DSRM-Schritt 4 und 5 nach Ken Peffers) und ist nicht mit dem Artefakt selbst gleichzusetzen. Das Artefakt existiert konzeptionell unabhängig von einer spezifischen Cloud-Plattform.

3.4.5 Abgrenzung gegenüber alternativen Forschungsansätzen

Die vorliegende Arbeit ist explizit im Paradigma der Design Science Research (DSR) verortet. Eine Einordnung als reine Architekturentwicklung oder als technisches Engineering-Projekt ist nicht zutreffend, da das Ziel nicht die Implementierung einer projektspezifischen Lösung, sondern die Entwicklung generalisierbaren Designwissens ist.

Im Unterschied zu Architektur-Engineering adressiert das entwickelte Artefakt kein singuläres Anwendungsszenario, sondern formuliert eine abstrahierte

Referenzarchitektur mit wiederverwendbaren Design-Prinzipien und formalisierten Kontrollmechanismen.
Ebenso unterscheidet sich die Arbeit von Action Research, da keine organisationale Intervention oder ko-kreative Implementierung in einem spezifischen Unternehmenskontext erfolgt. Der Fokus liegt auf der systematischen Konstruktion, Demonstration und Evaluation eines Artefakts gemäß dem DSRM-Prozessmodell nach Peffers et al. Schließlich geht die Arbeit über ein rein konzeptionelles Framework hinaus, da die entwickelten Design-Prinzipien technisch instanziiert und hinsichtlich ihrer Durchsetzbarkeit, Nachweislogik und Integrationsfähigkeit empirisch überprüft werden. Damit erfüllt die Arbeit die Leitlinien G1–G7 nach Alan R. Hevner und ist klar als gestaltungsorientierter Forschungsbeitrag zu klassifizieren.

3.5 Anforderungserhebung und -analyse

Die Anforderungserhebung bildet den Relevance Cycle der vorliegenden Arbeit und überführt regulatorische, technische und strategische Anforderungen systematisch in einen strukturierten Anforderungskatalog (R-Katalog). Dieser Katalog dient als Eingabe für den Design Cycle und als Referenz für die spätere Evaluation.
Die Erhebung erfolgt auf Basis dreier Quellenkategorien: (1) regulatorische Primärquellen, insbesondere die Art. 9–15 des EU AI Act (VO 2024/1689) sowie die Anhänge III und IV, (2) normative Rahmenwerke, insbesondere NIST AI RMF (als methodischer Governance-Rahmen) und ISO 27001 (Informationssicherheit), wobei ISO 42001:2023 als verwandter Standard eingeordnet, jedoch nicht als direkte Anforderungsquelle für die Referenzarchitektur herangezogen wird, sowie (3) die wissenschaftliche Fachliteratur zu LLMOps, Referenzarchitekturen und AI Governance. Durch diese Triangulation der Quellenbasis wird sichergestellt, dass der Anforderungskatalog sowohl regulatorisch vollständig als auch technisch operationalisierbar und wissenschaftlich fundiert ist.
Die erhobenen Anforderungen werden nach dem MUSS/SOLL-Schema klassifiziert: MUSS-Anforderungen leiten sich direkt aus regulatorischen Vorgaben ab und sind für die Konformität zwingend erforderlich. SOLL-Anforderungen ergänzen den Katalog um fachlich empfohlene Praktiken aus Literatur und Normung, die die Qualität und Praxistauglichkeit der Architektur erhöhen, aber keine regulatorische Pflicht darstellen. Die Detaildarstellung des Anforderungskatalogs erfolgt in Kapitel 4.

3.6 Traceability-Ansatz

Ein zentrales methodisches Merkmal der vorliegenden Arbeit ist die durchgehende Nachverfolgbarkeit (*Traceability*) von der Forschungsfrage über die Anforderung bis zum Evaluationsnachweis. Dieser Ansatz dient zwei Zwecken: Erstens sichert er die interne Konsistenz des Forschungsprozesses, indem jede Designentscheidung auf eine explizite Anforderung zurückgeführt werden kann. Zweitens stärkt er die Validität der Evaluation, da die Evaluationskriterien direkt aus den Anforderungen abgeleitet werden und somit die Bewertung des Artefakts auf eine nachvollziehbare Grundlage gestellt wird.

Die Traceability-Kette verläuft entlang folgender Elemente: Forschungsfrage (RQ) → Anforderung (R) → Design-Prinzip (DP) → Quality Gate (Gate) → Evidence-Artefakt → Evaluationskriterium. Jedes Element ist über eine eindeutige Kennung referenzierbar, sodass bidirektionale Nachverfolgbarkeit gewährleistet ist: Von jeder Forschungsfrage lässt sich vorwärts bis zum Evaluationsnachweis navigieren, und von jedem Gate rückwärts bis zur regulatorischen Anforderung.

Dieser Traceability-Ansatz reflektiert die von Hevner et al. (2004, S. 83, G5) geforderte Forschungsrigorosität, indem er die Konstruktionsentscheidungen transparent und reproduzierbar dokumentiert. Er operationalisiert zugleich das Prinzip DP2 (Traceability-Kette) auf methodischer Ebene.

3.7 Evaluationsdesign

Die Evaluation des Artefakts folgt einer dreistufigen Strategie, die unterschiedliche Evaluationsziele durch komplementäre Methoden adressiert. Diese Mehrstufigkeit entspricht der Forderung von Hevner et al. (2004, S. 83, G3), dass Nützlichkeit, Qualität und Wirksamkeit eines Artefakts rigoros durch geeignete Evaluationsmethoden nachgewiesen werden müssen.

Stufe (a): Requirements-Coverage-Matrix. Die erste Evaluationsstufe prüft die Vollständigkeit des Artefakts gegenüber dem Anforderungskatalog. Für jede Anforderung (R1–Rn) wird dokumentiert, welche architekturellen Komponenten, Gates und Design-Prinzipien sie adressieren. Diese Stufe beantwortet die Frage, ob das Artefakt den gesamten Anforderungsraum abdeckt.

Stufe (b): Proof-of-Concept-Walkthrough. Die zweite Evaluationsstufe validiert durch den PoC-Walkthrough die technische Durchsetzung (Policy-Enforcement) sowie die Integrität der erzeugten Evidenz des Azure-basierten PoC. Dieser umfasst die Ausführung ausgewählter Quality Gates, die Überprüfung der Policy-

Enforcement-Mechanismen (OPA/Rego) und den Nachweis der Evidenzsicherung (immutable Storage). Die Stufe entspricht DSRM-Schritt 4 (Demonstration) nach Peffers et al. (2007, S. 55). Dabei werden sowohl positive als auch negative Gate-Durchläufe berücksichtigt, um nicht nur die Funktionsfähigkeit, sondern explizit die technische Durchsetzung (Enforcement) der definierten Policies zu validieren. Die Evaluation prüft somit, ob bei Nichterfüllung von Kriterien ein Deployment technisch blockiert wird.

Ergänzend wird die Integrität der erzeugten Evidenzartefakte überprüft, insbesondere hinsichtlich Persistierung, Versionierung und Unveränderlichkeit. Damit adressiert die Evaluation nicht nur die Durchsetzung, sondern auch die auditierbare Nachweisbarkeit regulatorischer Anforderungen im Sinne von Accountability-by-Design.

Stufe (c): Expert-Reviews. Die dritte Evaluationsstufe erhebt die Einschätzung von Domänenexperten (n ≥ 4) zur Praxistauglichkeit, Vollständigkeit und Anwendbarkeit der Referenzarchitektur. Diese qualitative Evaluation ergänzt die analytischen Stufen (a) und (b) um eine praxisnahe Perspektive und adressiert insbesondere die Frage der *Utility* im realen Enterprise-Kontext.

Die Evaluationskriterien sind entlang der drei Gate-Dimensionen (strategisch, technisch, Compliance) strukturiert. Tabelle 6 zeigt die Zuordnung der Kriterien zu Methoden und Evaluationsstufen.

Tabelle 6: Evaluationskriterien nach Gate-Dimensionen

Gate-Dimension	Kriterium	Methode	Stufe
Strategisch	Vollständigkeit (jede Phase ≥ 1 Gate)	Coverage-Matrix	(a)
Strategisch	Nachvollziehbarkeit (Audit Trail)	PoC-Walkthrough	(b)
Strategisch	Praxistauglichkeit	Expert-Review	(c)
Technisch	Korrektheit (OPA/Rego pass/fail)	PoC-Walkthrough	(b)
Technisch	Abdeckung GenAI-Metriken	Coverage-Matrix	(a)
Technisch	Automatisierbarkeit (CI/CD-Trigger)	PoC-Walkthrough	(b)

Compliance	Rechtskonformität (Art. 9–15 → Policies)	Coverage-Matrix	(a)
Compliance	Evidenzsicherung (immutable Storage)	PoC-Walkthrough	(b)
Compliance	Audit-Readiness	Expert-Review	(c)

Die Kombination der drei Stufen realisiert eine methodische Triangulation: Die Coverage-Matrix sichert die analytische Vollständigkeit, der PoC-Walkthrough die technische Machbarkeit und die Expert-Reviews die praktische Nützlichkeit. Diese Triangulation adressiert die von Hevner et al. (2004, S. 83, G3) geforderte rigorose Evaluation aus unterschiedlichen Perspektiven.

3.8 Interviewdesign und Auswertung

Die Expert-Reviews (Evaluationsstufe c) werden als leitfadengestützte Experteninterviews durchgeführt. Die Auswahl der Experten folgt einer gezielten Stichprobenziehung (*purposive sampling*), die sicherstellt, dass die Perspektiven der zentralen Stakeholder-Gruppen – Enterprise Architecture, LLMOps/DevOps, Compliance/Governance und AI Engineering – vertreten sind. Es werden mindestens 3 Experten befragt, um eine Mindestbreite an Perspektiven zu gewährleisten.

Der Interviewleitfaden ist semistrukturiert und gliedert sich entlang der drei Gate-Dimensionen (strategisch, technisch, Compliance). Für jede Dimension werden die Experten gebeten, die Referenzarchitektur hinsichtlich Vollständigkeit, Praxistauglichkeit und Verbesserungspotenzial zu bewerten. Der Leitfaden enthält sowohl geschlossene Bewertungsfragen (z. B. Likert-Skala zur Praxistauglichkeit) als auch offene Fragen zur Erfassung qualitativer Einschätzungen und Verbesserungsvorschläge.

Die Auswertung erfolgt mittels qualitativer Inhaltsanalyse nach Mayring (2015). Die Interviews werden transkribiert und anhand eines deduktiven Kategoriensystems codiert, das sich an den Evaluationskriterien (Tabelle 6) orientiert. Ergänzend werden induktive Kategorien gebildet, um unerwartete Erkenntnisse systematisch zu erfassen.

Die Gütekriterien der qualitativen Forschung werden durch folgende Maßnahmen adressiert: Die *Nachvollziehbarkeit* wird durch die vollständige Dokumentation des Interviewleitfadens, der Transkripte und des Codierungsprozesses sichergestellt. Die *Intersubjektivität* wird durch die Offenlegung der Auswahlkriterien und des

Auswertungsverfahrens gewährleistet. Die *Triangulation* erfolgt durch die Kombination mit den analytischen Evaluationsstufen (a) und (b), sodass die Expertenbewertungen nicht isoliert, sondern im Kontext der Gesamtevaluation interpretiert werden.