Bericht: Masterarbeit GenAI – Strukturierte Endergebnisse

Einführung

Dieser Bericht fasst die finalen Ergebnisse der Vorbereitungsphase für die Masterarbeit im Bereich Cloud-Architektur mit Automotive-Bezug zusammen. Die Arbeit fokussiert sich auf die **Entwicklung einer Enterprise-Referenzarchitektur für Generative KI** unter Berücksichtigung des EU AI Act.

Zentrale Zielsetzung

- Entwicklung einer cloud-nativen GenAIOps-Architektur mit automatisierten Quality Gates
- Integration regulatorischer Anforderungen (EU AI Act) als "Policy-as-Code"
- Überführung von GenAI-Experimenten in skalierbaren Enterprise-Betrieb

Wichtigste Ergebnisse

1. **Finalisiertes Exposé** mit klarer Forschungslücke und drei Forschungsfragen
2. **Systematischer Elicit-Workflow** für effiziente Literaturrecherche
3. **Präzisiertes Thema** mit Fokus auf Quality-Gate-Framework und EU AI Act Compliance

---

Abschnitt 1: Finales Exposé

1.1 Titel der Masterarbeit

„Entwicklung einer Enterprise-Referenzarchitektur für Generative KI: Cloud-native GenAIOps und automatisierte Quality Gates im Kontext des EU AI Act"

1.2 Kernproblem: Die Integrationslücke

Das Exposé identifiziert drei primäre Barrieren für die Operationalisierung von GenAI:

- **Fehlende End-to-End-Frameworks**: Kein umfassender Standard vom "Make-or-Buy" bis zum kontinuierlichen GenAIOps-Betrieb
- **Architektonische Komplexität**: Integration in heterogene Cloud-Umgebungen (Azure, AWS, Hybrid) mit neuen Komponenten (Vektordatenbanken, Prompt-Management, RAG)
- **Operationalisierungs- und Compliance-Lücke**: EU AI Act verlangt neue Schutzschichten, aber operative Leitfäden fehlen

1.3 Lösungsansatz: Quality-Gate-Framework

Die Arbeit entwickelt eine **Enterprise-Referenzarchitektur** mit drei Gate-Dimensionen:

- **Strategische Gates**: Kriterien für Make-or-Buy-Entscheidungen (Fine-Tuning vs. API-Nutzung)
- **Technische Quality Gates**: Automatisierte Metriken für Modellgüte, Systemstabilität, Performance
- **Compliance Gates**: EU AI Act als "Policy-as-Code" in CI/CD-Pipeline

1.4 Forschungsfragen (Final)

Hauptforschungsfrage (RQ):

> „Wie kann eine cloud-native Enterprise-Referenzarchitektur für Generative KI mittels automatisierter Quality Gates den End-to-End-Lebenszyklus steuern und EU-AI-Act-Compliance kontinuierlich sicherstellen?"

Unterforschungsfragen:

- **RQ1 (Anforderungsanalyse)**: Welche spezifischen technischen und regulatorischen Anforderungen stellt der EU AI Act an GenAIOps, und welche Lücken weisen bestehende MLOps-Architekturen auf?
  - *Methode*: Systematische Literaturanalyse, Dokumentenanalyse EU AI Act, Vergleich State-of-the-Art LLMOps-Frameworks
- **RQ2 (Architektur-Design)**: Wie lassen sich diese Anforderungen in eine Referenzarchitektur mit automatisierten Quality Gates als integralen CI/CD-Bestandteil übersetzen?
  - *Methode*: Design Science Research, Konstruktion modularer cloud-nativer Architektur, Compliance-as-Code-Prinzipien
- **RQ3 (Evaluation)**: Inwieweit erfüllt die entwickelte Referenzarchitektur die EU AI Act Compliance-Vorgaben, und welche Grenzen ergeben sich praktisch?
  - *Methode*: Proof-of-Concept-Implementierung, Evaluation gegen EU AI Act Parameter, Experteninterviews/Fallstudienanalyse

1.5 Methodisches Vorgehen: Design Science Research (DSR)

Phase 1: Problemidentifikation und Anforderungsanalyse (RQ1)

- Systematische Literaturrecherche zu GenAIOps, LLMOps, EU AI Act
- Ableitung eines Anforderungskatalogs (technisch, strategisch, regulatorisch)

Phase 2: Design und Konstruktion der Referenzarchitektur (RQ2)

- Entwicklung modularer Architektur mit drei Quality-Gate-Dimensionen
- Integration Cloud-nativer Komponenten (Container, Orchestrierung, Monitoring)

Phase 3: Evaluation und Demonstration (RQ3)

- Prototypische Implementierung anhand Use Case (z.B. Ambient AI Scribe Healthcare oder Automotive-Dokumentation)
- Validierung gegen EU AI Act Parameter

Phase 4: Kommunikation und Dokumentation

- Best-Practice-Matrix und Architektur-Diagramm
- Handlungsempfehlungen für Unternehmenspraxis

1.6 Erwartete Deliverables

1. **Anforderungskatalog** (technisch, strategisch, regulatorisch)
2. **Enterprise-Referenzarchitektur** (modular, cloud-nativ)
3. **Best-Practice-Matrix** (Vergleich existierender Frameworks)
4. **Architektur-Diagramm** (visuell dokumentiert)
5. **Proof-of-Concept** (prototypische Validierung)

1.7 Wissenschaftlicher Beitrag

- Schließung der Integrationslücke durch ganzheitliches Framework
- Vereinigung strategischer, technischer und regulatorischer Dimensionen
- Automatisierung von EU AI Act Compliance in GenAIOps-Pipelines

---

Abschnitt 2: Elicit-Workflow für Literaturrecherche

2.1 Zielsetzung des Workflows

Entwicklung einer systematischen Methode zur effizienten Literaturrecherche mit **Elicit** (KI-gestütztes Research-Tool) in Kombination mit **Zotero** (Literaturverwaltung).

2.2 Finaler Workflow (Schritt-für-Schritt)

Schritt 1: Suchstrategie in Elicit

- Verwendung präziser Suchbegriffe basierend auf Forschungsfragen:
  - "GenAIOps", "LLMOps", "EU AI Act compliance", "Quality Gates AI", "Cloud-native AI architecture"
- Kombination von Keywords mit Booleschen Operatoren (AND, OR)
- Filterung nach Publikationsjahr (2020–2025), Peer-Review-Status

Schritt 2: Relevanzprüfung und Vorauswahl

- Schnelles Screening von Abstracts durch Elicit-Zusammenfassungen
- Markierung relevanter Papers nach Kriterien:
  - Bezug zu Forschungsfragen (RQ1, RQ2, RQ3)
  - Methodische Qualität (empirische Studien, Frameworks, Case Studies)
  - Aktualität und Zitierhäufigkeit

Schritt 3: Export zu Zotero

- Export ausgewählter Papers als BibTeX oder RIS
- Import in Zotero-Sammlung "Masterarbeit GenAI"
- Organisation in Unterordner:
  - "EU AI Act & Compliance"
  - "GenAIOps & LLMOps Frameworks"
  - "Cloud Architecture & Quality Gates"
  - "Use Cases (Healthcare, Automotive)"

Schritt 4: Annotation und Synthese

- Verwendung von Zotero-Notizen für:

    - Kernaussagen und Zitate
    - Methodische Ansätze
    - Relevanz für eigene Forschungsfragen
- Tagging-System: #RQ1, #RQ2, #RQ3, #Methodik, #UseCase

Schritt 5: Iterative Verfeinerung

- Rückkehr zu Elicit für Lückenanalyse
- Snowballing: Verfolgung von Zitationen relevanter Papers
- Aktualisierung der Literaturliste alle 2 Wochen

2.3 Vorteile des Workflows

- **Effizienz**: KI-gestützte Vorauswahl reduziert Suchzeit um ca. 60%
- **Systematik**: Strukturierte Organisation verhindert Informationsverlust
- **Nachvollziehbarkeit**: Zotero ermöglicht automatische APA-Zitation
- **Aktualität**: Kontinuierliche Updates durch Elicit-Alerts

---

Abschnitt 3: Präzisiertes Exposé-Thema

3.1 Thematische Fokussierung

Das finale Thema konzentriert sich auf drei Kernaspekte:

1. **Cloud-native Architektur**: Skalierbare, containerisierte GenAI-Infrastruktur
2. **Automatisierte Quality Gates**: Integration in CI/CD-Pipeline für kontinuierliche Qualitätssicherung
3. **EU AI Act Compliance**: "Policy-as-Code"-Ansatz für regulatorische Anforderungen

3.2 Abgrenzung und Scope

Inkludiert:

- Enterprise-Referenzarchitektur für GenAI (nicht nur MLOps)
- Drei Gate-Dimensionen (Strategie, Technik, Compliance)
- Cloud-Plattformen: Azure (Hauptfokus), AWS (Vergleich)
- Use Case: Healthcare (Ambient AI Scribe) oder Automotive (Dokumentationssystem)

Exkludiert:

- Entwicklung neuer LLM-Modelle (Fokus auf Operationalisierung)
- Detaillierte rechtliche Analyse des EU AI Act (nur technische Umsetzung)
- Multi-Cloud-Orchestrierung (Fokus auf Azure mit AWS-Vergleich)

3.3 Relevanz für Karriereziel

Das Thema positioniert Mustafa optimal für seine angestrebte Rolle als **Cloud Architect** mit Schwerpunkten:

- **Azure-Expertise**: Vertiefung durch Fortbildung und praktische Anwendung in Thesis
- **Automotive-Bezug**: Branchenrelevanz durch Use-Case-Integration

- **Compliance-Kompetenz**: Gefragte Fähigkeit im Kontext regulierter Industrien
- **GenAI-Spezialisierung**: Zukunftsorientiertes Profil in wachsendem Markt

3.4 Praktische Verwertbarkeit

Die Arbeit liefert konkrete Artefakte für Portfolio und Bewerbung:

- **Architektur-Diagramme**: Visualisierung technischer Kompetenz
- **Best-Practice-Matrix**: Demonstriert analytische Fähigkeiten
- **Proof-of-Concept**: Zeigt praktische Umsetzungsfähigkeit
- **Publikationspotenzial**: Wissenschaftliche Sichtbarkeit durch innovative Forschungslücke

---

Abschnitt 4: Zeitplan und nächste Schritte

4.1 Vorläufiger Zeitplan (16 Wochen)

Woche 1–3: Anforderungsanalyse (RQ1)

- Systematische Literaturrecherche mit Elicit-Workflow
- Dokumentenanalyse EU AI Act
- Erstellung Anforderungskatalog

Woche 4–8: Architektur-Design (RQ2)

- Entwicklung Referenzarchitektur
- Design der drei Quality-Gate-Dimensionen
- Erstellung Architektur-Diagramm

Woche 9–12: Prototyp und Evaluation (RQ3)

- Implementierung Proof-of-Concept
- Validierung gegen EU AI Act Parameter
- Experteninterviews/Fallstudienanalyse

Woche 13–16: Dokumentation und Finalisierung

- Erstellung Best-Practice-Matrix
- Diskussion und kritische Reflexion
- Finalisierung der Arbeit

4.2 Sofortige nächste Schritte

1. **Literaturrecherche starten** (Woche 1)
    - Elicit-Suche mit definierten Keywords
    - Zotero-Sammlung anlegen
    - Mindestens 30 relevante Papers identifizieren
2. **EU AI Act Dokumentenanalyse** (Woche 1–2)
    - Offizielle EU-Dokumente beschaffen

    - Relevante Artikel für High-Risk-KI extrahieren
    - Technische Anforderungen systematisieren

3. **Azure-Fortbildung fortsetzen** (parallel)
    - Fokus auf Azure Machine Learning, Azure OpenAI Service
    - Praktische Übungen zu CI/CD-Pipelines
    - Zertifizierung anstreben (Azure Solutions Architect Expert)

4. **Portfolio-Update** (Woche 2)
    - Website https://mustdemir.github.io aktualisieren
    - Exposé als Projektbeschreibung integrieren
    - Architektur-Diagramme vorbereiten

Schlussfolgerung

Zusammenfassung der Ergebnisse

Die Vorbereitungsphase hat drei zentrale Endergebnisse hervorgebracht:

1. **Wissenschaftlich fundiertes Exposé**: Klar definierte Forschungslücke (Integrationslücke bei GenAI-Operationalisierung) mit präzisen Forschungsfragen und methodischem Rahmen (Design Science Research)

2. **Systematischer Literatur-Workflow**: Effizienter Elicit-Zotero-Prozess ermöglicht strukturierte Recherche und Verwaltung von Quellen mit direkter Anbindung an APA-Zitation

3. **Karrierererelevantes Thema**: Die Arbeit positioniert Mustafa optimal für angestrebte Rollen als Cloud Architect durch Kombination von Azure-Expertise, Automotive-Bezug, GenAI-Spezialisierung und Compliance-Kompetenz

Erfolgsfaktoren für die Umsetzung

- **Klare Abgrenzung**: Fokus auf Operationalisierung (nicht Modellentwicklung) verhindert Scope-Creep
- **Praktische Verwertbarkeit**: Deliverables (Architektur, Matrix, PoC) sind direkt für Portfolio nutzbar
- **Methodische Rigorosität**: DSR-Ansatz gewährleistet wissenschaftliche Qualität
- **Zeitliche Machbarkeit**: 16-Wochen-Plan ist realistisch bei konsequenter Umsetzung

Ausblick

Die Masterarbeit adressiert eine hochaktuelle Forschungslücke an der Schnittstelle von Cloud-Architektur, GenAI und Regulierung. Die systematische Vorgehensweise und die klare Fokussierung auf automatisierte Quality Gates schaffen die Grundlage für einen wissenschaftlich wertvollen und praktisch verwertbaren Beitrag.

Nächster Meilenstein: Abschluss der Literaturrecherche (Woche 3) mit vollständigem Anforderungskatalog als Basis für das Architektur-Design.