Inhaltsverzeichnis

EXPOSÉ TEIL 1 2

1.1. ARBEITSTITEL 2

1.2 PROBLEMSTELLUNG - OPERATIVE UND KONZEPTIONELLE LÜCKEN IM ENTERPRISE-BETRIEB GENERATIVER KI-SYSTEME 2

1.2.1 Erste Problemdimension: Fragmentierung bestehender Operationalisierungs-frameworks 3

1.2.2 Zweite Problemdimension: Methodische Inadäquanz bestehender Qualitätssicherungsmechanismen für generative KI-Systeme 4

1.2.3 Problemdimension 3: Compliance-Operationalisierungslücke (EU AI Act) 5

1.3 ZIELSETZUNG DER ARBEIT UND LEITFRAGEN 8

1.4 METHODE 9

EXPOSÉ TEIL 2 10

2.1 MOTIVATION 10

2.2 UNTERNEHMENSAKZEPTANZ 10

2.3 ZEITPLAN 11

2.4 GROBGLIEDERUNG 12

LITERATURVERZEICHNIS (EXPOSÉ) 14

EXPOSÉ TEIL 1

1.1. Arbeitstitel

„Entwicklung einer Enterprise-Referenzarchitektur für Generative KI: Cloud-native GenAIOps und automatisierte Quality Gates im Kontext des EU AI Act."

1 Einleitung

Die rasante Adaption generativer KI (GenAI) und Large Language Models (LLMs) stellt Unternehmen vor neue operative Herausforderungen. Während klassische MLOps-Verfahren für prädiktive Modelle etabliert sind, fehlt es an End-to-End-Frameworks für den Lebenszyklus generativer KI („LLMOps"). Bestehende CI/CD-Pipelines decken die spezifischen Risiken stochastischer Modelle (z. B. Halluzinationen) nicht ab.

Die Dringlichkeit dieser Forschungslücke wird durch einen übergeordneten industriepolitischen Kontext verstärkt: Die Europäische Union hat in den vergangenen Jahren systematisch auf die strategische Abhängigkeit europäischer Unternehmen von US-amerikanischen Cloud-Infrastrukturanbietern hingewiesen und entsprechende Gegenmaßnahmen eingeleitet — von der GAIA-X-Initiative bis zur Europäischen Datenstrategie (Blancato, 2024, S. 12–14). Diese Forderung nach technologischer und datenbezogener Souveränität ist dabei nicht primär politischer Natur, sondern hat unmittelbare regulatorische Konsequenzen: Der EU AI Act verpflichtet Anbieter und Betreiber von Hochrisiko-KI-Systemen zur nachweisbaren Daten-Governance und Protokollierung über den gesamten Systemlebenszyklus (Art. 10, 12), was impliziert, dass die zugrundeliegende Infrastruktur auditierbar, jurisdiktionskonform und kontrollierbar sein muss. Bestehende GenAIOps-Frameworks adressieren diese Deployment-Dimension jedoch nicht — sie sind konzeptionell weitgehend auf US-Hyperscaler-Umgebungen ausgerichtet und lassen offen, wie eine cloud-native Betriebsarchitektur unter Souveränitätsbedingungen realisiert werden kann. Die vorliegende Arbeit setzt genau an dieser Schnittstelle an: Sie entwickelt eine Enterprise-Referenzarchitektur, die cloud-native GenAIOps-Praktiken mit automatisierten Quality Gates verbindet und dabei explizit deployment-agnostisch — das heißt auf Public Cloud, Sovereign Cloud und On-Premises-Umgebungen gleichermaßen anwendbar — konzipiert ist.

1.2 Problemstellung - Operative und konzeptionelle Lücken im Enterprise-Betrieb generativer KI-Systeme

Der produktive Betrieb generativer KI-Systeme, insbesondere großer Sprachmodelle (LLMs) und darauf aufbauender Retrieval-Augmented-Generation-(RAG-)Architekturen stellt Unternehmen vor qualitativ neue Herausforderungen, die mit etablierten MLOps-

Frameworks nur unzureichend adressiert werden können. Dieser Befund lässt sich (Sinha et al., 2024) entlang dreier interdependenter Problemdimensionen konkretisieren.

1.2.1 Erste Problemdimension: Fragmentierung bestehender Operationalisierungs-frameworks

Traditionelle MLOps-Ansätze wurden für diskriminative Modelle mit stabilen, strukturierten Datenpipelines konzipiert. Generative KI-Systeme unterscheiden sich fundamental durch probabilistisches Ausgabeverhalten, stochastische Qualitätsschwankungen, Promptabhängigkeit sowie erhöhte Anforderungen an Observability und Sicherheitsbewertung (Sinha et al., 2024, S. 1–2). Bestehende Frameworks adressieren dabei typischerweise isolierte Lebenszyklusphasen — etwa Training, Deployment oder Monitoring — ohne eine integrierte End-to-End-Governance zu ermöglichen. Beispielsweise stellen Kun Wang et al. fest, dass aktuelle Arbeiten zur LLM-Sicherheit sich auf einzelne Phasen fokussieren, anstatt eine kohärente Betrachtung des gesamten Systemlebenszyklus zu leisten (Wang et al., 2025, S. 1). Diaz-De-Arcaya et al. konstatieren entsprechend, dass die akademische Literatur eine durchgehende Abdeckung der LLMOps-Phasen vermissen lässt (Diaz-De-Arcaya et al., 2024, S. 3). Die Konsequenz dieser Fragmentierung ist in der unternehmerischen Praxis messbar: Stone et al. berichten, dass 55 % der befragten Unternehmen keine produktiven Modelle betreiben und 18 % mehr als 90 Tage für die Bereitstellung benötigen, ein Beobachtung, die auf systematische operative Defizite in bestehenden Ansätzen hindeutet, auch wenn Einzelfallgeneralisierungen methodisch mit Vorsicht zu bewerten sind (Stone et al., 2025, S. 1).

Die akademische Diskussion beschreibt eine evolutionäre Entwicklung von MLOps über LLMOps hin zu GenAIOps und AgentOps, wobei jedes nachfolgende Paradigma spezifische Unzulänglichkeiten seines Vorgängers adressiert (Joshi, 2025, S. 8; Pahune & Akhtar, 2025, S. 1). MLOps ist als operatives Fundament gut etabliert und umfasst bewährte Prinzipien, Architekturen und Workflows zur End-to-End-Automatisierung und Operationalisierung von Machine-Learning-Produkten (Kreuzberger et al., 2023, S. 31866–31879). LLMOps wird als spezialisierte Unterkategorie von MLOps verstanden, die sich auf den Betrieb großer Sprachmodelle konzentriert und dabei besondere Anforderungen wie Skalierbarkeit, Sicherheit und ethische Aspekte berücksichtigt (Pahune & Akhtar, 2025, S. 1, 10; Sinha et al., 2024, S. 2; Tantithamthavorn et al., 2025, S. 27). GenAIOps erweitert diese Konzepte als übergeordnetes Operationsparadigma um die spezifischen Komplexitäten generativer KI-Systeme im Enterprise-Umfeld – einschließlich erweitertem Monitoring, Prompt-Management und Agenten-Debugging (Joshi, 2025, S. 7–8). Da GenAIOps LLMOps konzeptuell einschließt (vgl. Pahune & Akhtar, 2025, S. 3), gelten die für LLMOps identifizierten offenen Herausforderungen

gleichermaßen – und in erweiterter Form – für den GenAIOps-Kontext (Pahune & Akhtar, 2025, S. 22). Trotz erster konzeptueller Integrationsversuche (Joshi, 2025, S. 7; Sinha et al., 2024, S. 3) ist GenAIOps als operativer Rahmen bislang weder konzeptuell vollständig konsolidiert noch in eine standardisierte Enterprise-Referenzarchitektur überführt worden. Insgesamt zeigt sich ein klarer Trend zur kontinuierlichen Verbesserung und Anpassung der Betriebsparadigmen für KI-Systeme (Kreuzberger et al., 2023, S. 31876; Pahune & Akhtar, 2025, S. 22–23), **wobei die formale Etablierung eines integrierten GenAIOps-Frameworks – das Cloud-native Prinzipien, Governance-Mechanismen und regulatorische Compliance systematisch integriert – weiterhin eine offene Forschungsfrage darstellt** (Joshi, 2025, S. 8; Pahune & Akhtar, 2025, S. 23; Tantithamthavorn et al., 2025, S. 27).

Diese Lifecycle-Fragmentierung hat unmittelbare Konsequenzen für die Qualitätssicherung: Wo kein integriertes Framework die Phasenübergänge strukturiert, fehlt auch die Grundlage für phasenübergreifende Qualitätskontrollmechanismen — ein Defizit, das die folgende Problemdimension vertieft.

1.2.2 Zweite Problemdimension: Methodische Inadäquanz bestehender Qualitätssicherungsmechanismen für generative KI-Systeme

Die in Problemdimension 1 beschriebene Fragmentierung bestehender Operationalisierungsframeworks wird durch eine methodische Lücke in der Qualitätssicherung verschärft: Die etablierten Verfahren zur Qualitätskontrolle in MLOps-Pipelines basieren auf deterministischen Metriken wie Accuracy, F1-Score oder AUC-ROC, die für diskriminative Modelle mit stabilen Ein-/Ausgabebeziehungen konzipiert wurden (Polyakovska, 2025, S. 5) Generative KI-Systeme erzeugen jedoch stochastische, kontextabhängige Outputs, deren Qualität nicht mit einzelnen numerischen Schwellenwerten erfasst werden kann. Polyakovska et al. konstatieren, dass traditionelle MLOps-Methoden keine angemessene Qualitätskontrolle und Skalierbarkeit für LLMs bieten. Diese methodische Inadäquanz manifestiert sich in drei konkreten Defiziten (Polyakovska, 2025, S. 2).

Erstens fehlen standardisierte Evaluationsmetriken für GenAI-spezifische Risikodimensionen (Xu et al., 2025, S. 14) identifizieren einen Mangel an standardisierten Evaluationsmetriken für verschiedene Funktionalitäten in RAG-Systemen. Ohne messbare, reproduzierbare Kriterien für Retrieval-Precision, Generierungsqualität, Halluzinations-Raten oder Prompt-Injection-Vulnerabilities können keine automatisierten Schwellenwerte definiert werden, an denen eine Freigabe- oder Ablehnungsentscheidung systematisch getroffen wird. Die Konsequenz ist, dass Qualitätsentscheidungen in der Praxis ad hoc und manuell erfolgen, was bei steigender Deployment-Frequenz nicht skaliert.

Zweitens ist die Observability-Infrastruktur für generative KI-Systeme unzureichend entwickelt. (Xu et al., 2025, S. 15) und (Polyakovska, 2025, S. 6–7) identifizieren begrenzte Unterstützung für Observability im Retrieval-Prozess sowie Herausforderungen bei der Entkopplung von Qualitätsaspekten im Monitoring. Jede formalisierte Qualitätskontrolle setzt nachprüfbare Evidenz voraus — etwa Monitoring-Metriken, Test-Reports oder Audit-Logs. Wenn die infrastrukturellen Grundlagen zur Erzeugung und Persistierung dieser Evidenz fehlen, bleibt Qualitätssicherung notwendig informell und nicht reproduzierbar.

Drittens fehlt eine phasenübergreifende Orchestrierung von Qualitätskontrollpunkten über den GenAI-Lebenszyklus hinweg. Die in Problemdimension 1 beschriebene Lifecycle-Fragmentierung hat zur Folge, dass auch Qualitätsprüfungen isoliert innerhalb einzelner Phasen stattfinden, ohne definierte Abhängigkeiten oder Übergabekriterien zwischen den Phasen (Wang et al., 2025, S. 1–2) Ein systematisches Zusammenspiel, bei dem etwa eine Deployment-Freigabe die erfolgreiche Absolvierung vorgelagerter Qualitäts- und Sicherheitsprüfungen voraussetzt, ist in bestehenden Frameworks konzeptionell nicht angelegt (Wang et al., 2025, S. 1–2).

Diese drei Defizite — fehlende Metriken, unzureichende Observability, fehlende Orchestrierung — beschreiben zusammengenommen eine strukturelle Lücke: Für generative KI-Systeme existieren keine formalisierten, automatisierbaren Kontrollpunkte, die den Übergang zwischen Lebenszyklusphasen an prüfbare Qualitätskriterien und nachweisbare Evidenz binden. Damit fehlt eine zentrale Voraussetzung sowohl für die technische Qualitätssicherung als auch für die regulatorische Nachweisführung, die Gegenstand der dritten Problemdimension ist. (Wang et al., 2025, S. 1–4, 70)

1.2.3 Problemdimension 3: Compliance-Operationalisierungslücke (EU AI Act)

Problem. Selbst wenn ein integriertes GenAI-Lifecycle-Framework (PD1) sowie belastbare Qualitätsmethoden (PD2) verfügbar wären, bleibt die regulatorische Nachweisbarkeit als eigenständige Engstelle bestehen. Der EU AI Act definiert für Hochrisiko-KI-Systeme verbindliche Anforderungen an ein Risikomanagementsystem über den gesamten Lebenszyklus (Art. 9), an Daten- und Daten-Governance (Art. 10), an Technische Dokumentation (Art. 11), Aufzeichnung/Protokollierung (Art. 12), Transparenz und Betreiberinformationen (Art. 13), menschliche Aufsicht (Art. 14) sowie Genauigkeit, Robustheit und Cybersicherheit (Art. 15) (Europäische Union, 2024, S. 56–61). Diese Normen sind jedoch primär als juristisch-normative Pflichten formuliert; sie liefern nicht automatisch eine technische Übersetzung in maschinenprüfbare Controls/Policies und eine durchgängige Evidenzkette für Audits.

Defizit 1 – Fehlende Übersetzung: von Normen zu automatisierbaren, prüfbaren Kontrollen. In der Trustworthy-AI-Literatur wird explizit hervorgehoben, dass eine klare Abbildung von Prinzipien und Anforderungen in operative Protokolle, die automatisiert und verifiziert werden können, nicht konsistent existiert (Díaz-Rodríguez et al., 2023, S. 14). Gleichzeitig wird die Governance-Forschung als noch deutlich unterentwickelt gegenüber der Geschwindigkeit der technologischen Entwicklung beschrieben (Taeihagh, 2025, S. 2). Verschärfend kommt hinzu, dass die schnelle technologische Entwicklung regulatorische Lücken erzeugt hat, die zu einer reaktiven statt vorausschauenden und adaptiven Governance geführt haben (Taeihagh, 2025, S. 7). Für die praktische Umsetzung bedeutet das: Zwischen den abstrakten AI-Act-Pflichten (z. B. „Risikomanagementsystem", „angemessene Transparenz", „wirksame menschliche Aufsicht") und konkreten Pipeline-Artefakten (Checks, Gate-Kriterien, Policy-Regeln, Evidence-Logs) besteht eine systematische Lücke (Europäische Union, 2024, S. 56–60).

Defizit 2 – Dokumentations- und Evidenzanforderungen sind hoch, aber operativ schwer skalierbar. Der AI Act verlangt u. a. die Erstellung und Aktualisierung technischer Dokumentation vor Inverkehrbringen/Inbetriebnahme (Art. 11) sowie automatische Protokollierung während des Systemlebenszyklus (Art. 12) (Europäische Union, 2024, S. 58–59). Empirische Software-Engineering-Arbeit zeigt, dass genau diese Technical-Documentation-Compliance organisatorisch anspruchsvoll ist: Sie erfordert kombinierte rechtliche und technische Expertise, die in der Praxis selten in ausreichender Tiefe vorhanden ist, und erzeugt entsprechend Kosten- und Aufwandsdruck – insbesondere für kleinere Anbieter (Sovrano et al., 2025, S. 1–2). Zudem können selbst gut gemeinte Erleichterungen (z. B. „equivalent documentation") zusätzliche Ambiguität und Genehmigungsabhängigkeit erzeugen, was die Operationalisierung weiter verkompliziert (Sovrano et al., 2025, S. 31). Damit bleibt Compliance-Nachweisführung häufig reaktiv (Dokumentation wird im Nachgang „zusammengeschrieben") statt als kontinuierlicher, automatisierter Prozess entlang der Pipeline.

Defizit 3 – Compliance betrifft ein Regime-Bündel und braucht technische Durchsetzung, ist aber nicht systematisch „as-Code" integriert. Für GenAI verschränkt sich AI-Act-Compliance in der Praxis mit weiteren Rechtsbereichen (z. B. IP, Datenschutz, Cybersecurity). Novelli et al. zeigen etwa, dass der AI-Act-Rahmen bei GPAI/GenAI zusätzliche Transparenz- und Dokumentationspflichten adressiert (u. a. Training-Data-Transparenz und Dokumentationsanforderungen im Kontext von Art. 53) (Novelli et al., 2024, S. 2) und dass Compliance-Pflichten teilweise explizit technische und organisatorische Maßnahmen nahelegen, etwa zur Umsetzung von Rechteinhaber-Opt-outs (Novelli et al., 2024, S. 10). Parallel wird betont, dass Cybersicherheitsregime (z.

B. CRA) GenAI expliziter berücksichtigen und mit dem risikobasierten AI-Act-Ansatz verzahnt werden sollten (Novelli et al., 2024, S. 14). Zusätzlich verstärken EU-Strategien zur Daten- und Cloud-Souveränität die regulatorische und organisatorische Komplexität, indem sie regulatorische Anforderungen mit industriepolitischen Zielen koppeln (Blancato, 2024, S. 12–14). Obwohl in DevSecOps-Kontexten Security-Controls bereits als automatisierte Practices in Pipelines etabliert sind – etwa automatisierte Tests, Infrastructure-as-Code, Compliance-as-Code und kontinuierliches Monitoring (Sinan et al., 2025, S. 1–6) –, adressieren diese Ansätze primär Infrastruktur- und allgemeine Sicherheitskontrollen wie Verschlüsselung, Zugriffssteuerung oder Netzwerksegmentierung (Sinan et al., 2025, S. 2–3). Ein vergleichbar systematischer Ansatz, der AI-Act-spezifische Pflichten – wie Bias-Evaluation, Erklärbarkeit oder kontinuierliches Risikomonitoring – konsistent in Policy-/Compliance-as-Code überführt und über den GenAI-Lifecycle orchestriert, ist in der bestehenden Literatur nicht dokumentiert.

Ergebnis. Aufgrund dieser drei Defizite kann die Frage, ob EU-AI-Act-Compliance erfüllt und auditierbar nachgewiesen ist, derzeit nicht zuverlässig automatisiert beantwortet werden. Damit entsteht eine zentrale Forschungslücke: Es fehlt ein Ansatz, der AI-Act-Pflichten (insb. Art. 9–15) in maschinenprüfbare Policies/Controls übersetzt, diese als Quality/Compliance Gates phasenübergreifend orchestriert und die erforderliche Evidenz (Dokumentation, Logs, Oversight-Nachweise) kontinuierlich bereitstellt (Europäische Union, 2024, S. 56–61; Sovrano et al., 2025, S. 1–2; Díaz-Rodríguez et al., 2023, S. 14).

Synthese der Problemdimensionen und resultierende Forschungslücke

Die drei Problemdimensionen beschreiben zusammengenommen eine kumulative Lücke: Bestehende Operationalisierungsframeworks für generative KI-Systeme sind fragmentiert und adressieren isolierte Lebenszyklusphasen, ohne ein integriertes End-to-End-Management für den Enterprise-Kontext bereitzustellen (PD1). Innerhalb dieser fragmentierten Ansätze fehlen darüber hinaus formalisierte, automatisierbare Qualitätssicherungsmechanismen, die der stochastischen Natur generativer Systeme methodisch gerecht werden — weder hinsichtlich standardisierter Evaluationsmetriken noch hinsichtlich der Observability-Infrastruktur oder der phasenübergreifenden Orchestrierung von Kontrollpunkten (PD2). Selbst wenn beide Defizite adressiert wären, bliebe die regulatorische Nachweisbarkeit als eigenständige Engstelle bestehen, da eine systematische Übersetzung der EU-AI-Act-Anforderungen in maschinenprüfbare Policies, eine skalierbare Evidenzerzeugung und eine durchgängige Compliance-Orchestrierung entlang des Lebenszyklus in der bestehenden Literatur nicht dokumentiert sind (PD3).

Diese dreifache Lücke — strukturell (Lifecycle), methodisch (Qualitätssicherung), regulatorisch (Compliance-Operationalisierung) — begründet den Bedarf an einer integrierten Enterprise-Referenzarchitektur, die cloud-native GenAIOps-Praktiken mit automatisierten Quality Gates verbindet und die Anforderungen des EU AI Act als prüfbare Kontrollmechanismen in CI/CD/CT-Pipelines operationalisiert. Die Entwicklung dieser Architektur als generalisierbares, wiederverwendbares Artefakt im Sinne des Design Science Research nach Hevner et al. (2004) ist Gegenstand der vorliegenden Arbeit.

1.3 Zielsetzung der Arbeit und Leitfragen

Ziel der vorliegenden Arbeit ist die Entwicklung einer modularen, cloud-nativen Enterprise-Referenzarchitektur für den produktiven Betrieb generativer KI-Systeme, die automatisierte Quality Gates als zentrale Steuerungsmechanismen entlang des End-to-End-Lebenszyklus integriert und die Anforderungen des EU AI Act systematisch operationalisiert. Das Artefakt wird im Sinne des Design Science Research nach Hevner et al. (2004) als generalisierbares, wiederverwendbares Designwissen konzipiert — nicht als unternehmensspezifische Implementierung, sondern als übertragbare Referenzarchitektur mit expliziten Design-Prinzipien (DP-1 bis DP-n).

Die Architektur umfasst drei integrierte Bestandteile: (1) ein Schichten- und Modulmodell, das die zentralen Funktionsbereiche cloud-nativer GenAIOps-Umgebungen strukturiert (u. a. Data, Model, Serving, Monitoring, Security, Governance, Platform), (2) ein Quality-Gate-Framework, das Kontrollpunkte entlang dreier Dimensionen — strategisch (Lifecycle-Governance), technisch (Modellqualität, Performance, Safety) und Compliance (EU-AI-Act-Anforderungen) — formalisiert, sowie (3) eine Einbettungslogik, die diese Gates als Policy-as-Code- und Compliance-as-Code-Mechanismen in CI/CD/CT-Pipelines verankert, einschließlich definierter Trigger, Prüfkriterien, Evidenzartefakte und Freigabeentscheidungen.

Der Erreichungsgrad der Zielsetzung wird anhand einer vierstufigen Evaluation überprüft: einem Requirements-Coverage-Check, der die Rückverfolgbarkeit zwischen abgeleiteten Anforderungen und Architekturkomponenten sicherstellt; einem szenariobasierten Walkthrough am Anwendungsfall eines Ambient AI Scribe; einer prototypischen Implementierung (Proof of Concept), die exemplarisch ein technisches und ein Compliance Gate demonstriert; sowie leitfadengestützten Experteninterviews mit Domänenexperten aus Wissenschaft und Praxis.

Aus der in Abschnitt 1.2 identifizierten Forschungslücke leiten sich folgende Forschungsfragen ab:

Hauptforschungsfrage (HRQ): Wie muss eine cloud-native Enterprise-Referenzarchitektur gestaltet sein, damit automatisierte Quality Gates den End-to-End-

Lebenszyklus generativer KI-Systeme steuern und die kontinuierliche Einhaltung der Anforderungen des EU AI Act systematisch unterstützen?

RQ1: Welche technischen, organisatorischen und regulatorischen Anforderungen ergeben sich an den produktiven Betrieb generativer KI-Systeme in cloud-nativen Enterprise-Umgebungen unter Berücksichtigung des EU AI Act?

RQ2: Welche Design-Prinzipien und Architekturbausteine sind erforderlich, um ein integriertes Quality-Gate-Framework entlang des GenAI-Lebenszyklus in eine cloud-native Betriebsumgebung einzubetten?

RQ3: Inwieweit erfüllt die entwickelte Referenzarchitektur die abgeleiteten Anforderungen, und welche Stärken, Schwächen und Anpassungsbedarfe zeigen sich bei der prototypischen Anwendung und der Bewertung durch Domänenexperten?

1.4 Methode

Die vorliegende Arbeit folgt dem Design Science Research (DSR)-Paradigma, das auf die Konstruktion und Evaluation zweckgerichteter IT-Artefakte zur Lösung identifizierter organisationaler Probleme ausgerichtet ist (Hevner et al., 2004, S. 77). DSR ist für die Zielsetzung dieser Arbeit besonders geeignet, da das Forschungsziel nicht die Erklärung eines beobachteten Phänomens, sondern die präskriptive Gestaltung einer neuartigen Architekturlösung ist — ein Artefakttyp, der sich der Kategorie „Model" im Sinne von March und Smith (1995) zuordnen lässt (Hevner et al., 2004, S. 77).

Als Vorgehensmodell wird die Design Science Research Methodology (DSRM) nach Peffers et al. (2007) herangezogen, die sechs Aktivitäten in einer nominalen Sequenz strukturiert: (1) Problem Identification & Motivation, (2) Definition of Objectives, (3) Design & Development, (4) Demonstration, (5) Evaluation und (6) Communication (Peffers et al., 2007, S. 52–56). Der Einstieg erfolgt problemzentriert (problem-centered entry point), da die dreifache Forschungslücke aus Abschnitt 1.2 den Ausgangspunkt bildet. Zur Strukturierung und Kommunikation des Forschungsprojekts wird ergänzend das DSR Grid nach vom Brocke und Maedche (2019) herangezogen, das die sechs Kerndimensionen eines DSR-Projekts systematisiert.

Die Wissensbasis (Rigor Cycle) wird durch eine strukturierte Literaturanalyse aufgebaut, die bestehende Frameworks aus den Bereichen MLOps/LLMOps/GenAIOps, Cloud-native-Architektur, AI-Governance und Compliance-Automatisierung konsolidiert. Der Relevance Cycle verankert die Arbeit im Enterprise-Kontext durch die Ableitung technischer, organisatorischer und regulatorischer Anforderungen (RQ1), die als Anforderungskatalog (R1–Rn) formalisiert werden. Im Design Cycle werden aus diesen Anforderungen Design-Prinzipien (DP-1 bis DP-n) abgeleitet und iterativ in die Referenzarchitektur überführt (RQ2).

Die Evaluation erfolgt methodisch vierstufig: (1) ein Requirements-Coverage-Check prüft die Rückverfolgbarkeit zwischen Anforderungen und Architekturkomponenten, (2) ein szenariobasierter Walkthrough demonstriert die Architekturanwendung am Anwendungsfall eines Ambient AI Scribe, (3) eine prototypische Implementierung (PoC) validiert exemplarisch ein technisches und ein Compliance Gate in einer CI/CD-Pipeline, und (4) leitfadengestützte Experteninterviews bewerten die Architektur hinsichtlich Praxistauglichkeit, Vollständigkeit und Anpassungsbedarf (RQ3).

EXPOSÉ TEIL 2

2.1 Motivation

Die Themenwahl ist sowohl durch die berufliche Spezialisierung als auch durch ein weiterführendes Forschungsinteresse motiviert. Zurzeit absolviere ich parallel zur Masterarbeit eine zertifizierte Vollzeit-Weiterbildung zum Cloud Architect (810 UE, AZAV-zertifiziert) mit Schwerpunkt auf Kubernetes, Infrastructure-as-Code und CI/CD-Pipelines, die die technische Basis der Arbeit unmittelbar ergänzt. Im Masterstudium bildete Künstliche Intelligenz das Vertiefungsfach (Note: 1,0), ergänzt durch Praxisprojekte im Bereich KI-gestütztes Requirements Engineering und cloud-native Architekturentwicklung (jeweils Note: 1,0). Die berufliche Erfahrung im Automotive-Sektor — unter anderem als Projektleiter bei Mercedes-AMG und als strategische Produktmanager bei der Mercedes-Benz AG mit Verantwortung für Schnittstellenmanagement, Datenintegration und Governance-Strukturen — hat den Bedarf an integrierten, regulatorisch konformen Betriebsarchitekturen für KI-Systeme aus der Praxis heraus sichtbar gemacht.

Über das unmittelbare Berufsziel als AI & Cloud Solution Architect hinaus verfolge ich das Ziel einer Promotion im Bereich KI- und Innovationsmanagement. Die vorliegende Arbeit soll dafür eine methodisch und inhaltlich tragfähige Grundlage schaffen. Darüber hinaus ist die Überzeugung leitend, dass die technologische und regulatorische Souveränität Europas — insbesondere im Bereich Cloud-Infrastruktur und KI-Governance — eine eigenständige architektonische Antwort erfordert, zu der diese Arbeit einen konzeptionellen Beitrag leisten möchte.

2.2 Unternehmensakzeptanz

Vorerst wird die Arbeit als rein akademisches Forschungsprojekt ohne festen Praxispartner durchgeführt. Dies ist im Rahmen einer Design-Science-Research-Arbeit methodisch unproblematisch, da das zentrale Artefakt — eine generalisierbare Referenzarchitektur — nicht an einen spezifischen Unternehmenskontext gebunden ist, sondern als übertragbares Designwissen konzipiert wird (Hevner et al., 2004, S. 80). Die Evaluation stützt sich auf leitfadengestützte Experteninterviews mit Domänenexperten

aus Wissenschaft und Praxis, deren Zugang über das akademische und berufliche Netzwerk von mir gesichert ist. Für die prototypische Implementierung (PoC) stehen studentische Cloud-Ressourcen (Microsoft Azure) sowie Open-Source-Tooling zur Verfügung. Eine optionale Kooperation mit einem Startup zur Validierung des Ambient-AI-Scribe-Szenarios (oder eines ähnlichen Use Case) wird derzeit geprüft, ist für die Durchführbarkeit der Arbeit jedoch nicht erforderlich.

2.3 Zeitplan

Phase	Zeitraum	Aktivitäten
Phase 1: Grundlagen & Anforderungen	Monat 1	Literaturanalyse (Kap. 2), Anforderungsableitung (Kap. 4), Traceability-Matrix
Phase 2: Architekturentwicklung	Monat 1–3	Design-Prinzipien, Schichtenmodell, Quality-Gate-Framework, Pipeline-Integration (Kap. 5)
Phase 3: Evaluation	Monat 4-5	Coverage-Check, Walkthrough, PoC-Implementierung, Experteninterviews (Kap. 6)
Phase 4: Dokumentation & Abschluss	Monat 5	Diskussion (Kap. 7), Fazit (Kap. 8), Revision, Abgabe

2.4 Grobgliederung

1 Einleitung

1.1 Problemstellung und Relevanz

1.2 Zielsetzung der Arbeit

1.3 Forschungsfragen

1.4 Aufbau der Arbeit

1.5 Abgrenzung (Scope) & Annahmen

2 Theoretische Grundlagen und Stand der Forschung → Rigor Cycle

2.1 Begriffsabgrenzung und Systemkontext (LLM, GenAI-System, RAG, LLMOps, Quality Gate, Policy-as-Code).

2.2 Generative KI und LLMs

2.3 Cloud-native: Fokus auf Plattformfähigkeiten (Identity, Network, Observability, Policy)

2.4 Operationalisierung

2.4.1 Von MLOps zu LLMOps: Operationalisierung von KI-Systemen

2.4.2 Der EU AI Act: Regulatorischer Rahmen und technisch-organisatorische Anforderungen

2.5 Quality Gates: Definition, Konzepte und Einordnung

2.6 Compliance-as-Code und Policy-as-Code

2.7 Synthese: Forschungslücke und Handlungsbedarf

3 Forschungsdesign und Methodik

3.1 Design Science Research als Forschungsrahmen

3.2 Vorgehensmodell/Prozess (Peffers)

3.3 Artefaktdefinition & Scope (was ist Teil der Architektur, was nicht?)

3.4 Anforderungserhebung und -analyse (Literatur + EU AI Act Primärquelle)

3.5 Traceability-Ansatz (RQ ↔ R1–Rn ↔ Komponenten ↔ Evaluation)

3.6 Evaluationsdesign (Kriterien + Methodenmix)

3.7 Interviewdesign & Auswertung (Leitfaden, Sampling, Auswertelogik)

4 Anforderungsanalyse → Relevance Cycle / beantwortet RQ1

4.1 Ableitungslogik für testbare Anforderungen (MUSS/SOLL, Format R1–Rn, Evidenz, Lifecycle-Phase, Bezug EU AI ACT)

4.2 Technische Anforderungen

4.3 Organisatorische Anforderungen

4.4 Regulatorische Anforderungen
4.5 Konsolidierter Anforderungskatalog

5 Entwicklung der Referenzarchitektur → Design Cycle / beantwortet RQ2
5.1 Design-Prinzipien (DP-1..DP-n, begründet aus R1–Rn)
5.2 Architekturübersicht: Schichtenmodell, Module, Schnittstellen, Verantwortlichkeiten
5.3 Quality-Gate-Framework
5.3.0 Gate-Template (Trigger, Evidence, Policy, Decision, Owner, Audit Trail, Waiver)
- 5.3.1 Strategische Gates (Lifecycle Governance)
- 5.3.2 Technische Gates (Qualität/Performance/Safety-Evals, Monitoring)
- 5.3.3 Compliance Gates (EU AI Act → Policy-as-Code + Evidence)
- 5.3.4 Gate-Katalog (Übersichtstabelle über alle Gates)
5.4 Integration in CI/CD/CT-Pipelines (Policy Engine, Evidence Store, Automation Points)

6 Evaluation → beantwortet RQ3
6.0 Evaluationskriterien (z. B. Coverage, Automatisierbarkeit, Auditierbarkeit, Praxistauglichkeit)
6.1 Requirements-Coverage-Check
6.2 Szenario-basierter Walkthrough: Ambient AI Scribe
6.3 Prototypische Implementierung (PoC)
- 6.3.1 Technisches Quality Gate
- 6.3.2 Compliance Gate (Policy-as-Code)
6.4 Experteninterviews: Durchführung und Ergebnisse
6.5 Synthese der Evaluationsergebnisse

7 Diskussion
7.1 Beantwortung der Forschungsfragen
7.2 Wissenschaftlicher Beitrag und Einordnung
- 7.2.1 Design Knowledge: übertragbare Muster/Prinzipien (DSR-Beitrag)
7.3 Implikationen für die Praxis
7.4 Limitationen
7.5 Weiterer Forschungsbedarf

8 Fazit und Ausblick

Literaturverzeichnis (Exposé)

Blancato, F. G. (2024). The cloud sovereignty nexus: How the European Union seeks to reverse strategic dependencies in its digital ecosystem. *Policy & Internet*, *16*(1), 12–30. https://doi.org/10.1002/poi3.358

Díaz-De-Arcaya, J., Torre-Bastida, A. I., Zárate, G., Miñón, R., & Almeida, A. (2024). LLMOps: A State of the Art and Comprehensive Overview. *arXiv preprint*, arXiv:2407.11657. https://doi.org/10.15223/policy-029

Díaz-Rodríguez, N., Del Ser, J., Coeckelbergh, M., López de Prado, M., Herrera-Viedma, E., & Herrera, F. (2023). Connecting the dots in trustworthy Artificial Intelligence: From AI principles, ethics, and key requirements to responsible AI systems and regulation. *Information Fusion*, *99*, 101896. https://doi.org/10.1016/j.inffus.2023.101896

Europäische Union. (2024). *Verordnung (EU) 2024/1689 des Europäischen Parlaments und des Rates vom 13. Juni 2024 zur Festlegung harmonisierter Vorschriften für künstliche Intelligenz (Verordnung über künstliche Intelligenz)*. Amtsblatt der Europäischen Union, L 2024/1689. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, *28*(1), 75–105. https://doi.org/10.2307/25148625

Joshi, S. (2025). LLMOps, AgentOps, and MLOps for Generative AI: A Comprehensive Review. *International Journal of Computer Applications Technology and Research*. https://doi.org/10.7753/IJCATR1407.1001

Kreuzberger, D., Kühl, N., & Hirschl, S. (2023). Machine Learning Operations (MLOps): Overview, Definition, and Architecture. *IEEE Access*, *11*, 31866–31879. https://doi.org/10.1109/ACCESS.2023.3262138

March, S. T., & Smith, G. F. (1995). Design and natural science research on information technology. *Decision Support Systems*, *15*(4), 251–266. https://doi.org/10.1016/0167-9236(94)00041-2

Novelli, C., Casolari, F., Hacker, P., Spedicato, G., & Floridi, L. (2024). Generative AI in EU law: Liability, privacy, intellectual property, and cybersecurity. *Computer Law & Security Review*, *55*, 106066. https://doi.org/10.1016/j.clsr.2024.106066

Pahune, S., & Akhtar, Z. (2025). Transitioning from MLOps to LLMOps: Navigating the Unique Challenges of Large Language Models. *Information*, *16*(2), 87. https://doi.org/10.3390/info16020087

Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, *24*(3), 45–77. https://doi.org/10.2753/MIS0742-1222240302

Polyakovska, K. (2025). LLMOps: Adapting MLOps Strategies for Large Language Model Lifecycle Management. *arXiv preprint*, https://doi.org/10.36910/6775-2524-0560-2025-58-14

Sinan, M., Shahin, M., & Gondal, I. (2025). Integrating Security Controls in DevSecOps: Challenges, Solutions, and Future Research Directions. *Journal of Software: Evolution and Process*, *37*, e70029. https://doi.org/10.1002/smr.70029

Sinha, A., Arora, A., & Gupta, A. (2024). Building AI Agents: Challenges in LLM Productionization. https://doi.org/10.15223/policy-029

Sovrano, F., Hine, E., Anzolut, S., & Bacchelli, A. (2025). Simplifying software compliance: AI technologies in drafting technical documentation for the AI Act. *Empirical Software Engineering*, *30*, 91. https://doi.org/10.1109/ICECET61485.2024.10698359

Stone, J., Patel, R., Ghiasi, F., Mittal, S., & Rahimi, S. (2025). Navigating MLOps: Insights into Maturity, Lifecycle, Tools, and Careers. *2025 IEEE Conference on Artificial Intelligence (CAI)*, 643–650. https://doi.org/10.1109/CAI64502.2025.00118

Taeihagh, A. (2025). Governance of Generative AI. *Policy and Society*, *44*(1), 1–22. https://doi.org/10.1093/polsoc/puaf001

Tantithamthavorn, C. K., Palomba, F., Khomh, F., & Chua, J. J. (2025). MLOps, LLMOps, FMOps, and Beyond. *IEEE Software*, *42*(1), 26–32. https://doi.org/10.1109/MS.2024.3477014

vom Brocke, J., & Maedche, A. (2019). The DSR grid: Six core dimensions for effectively planning and communicating design science research projects. *Electronic Markets*, *29*(3), 379–385. https://doi.org/10.1007/s12525-019-00358-7

Wang, K., Zhang, G., Zhou, Z., Wu, J., Yu, M., Zhao, S., Yin, C., Fu, J., Yan, Y., Luo, H., Lin, L., Xu, Z., Lu, H., Cao, X., Zhou, X., Jin, W., Meng, F., Xu, S., Mao, J., … Liu, Y. (2025). *A Comprehensive Survey in LLM(-Agent) Full Stack Safety: Data, Training and Deployment* (Version 4). arXiv. https://doi.org/10.48550/ARXIV.2504.15585

Xu, X., Weytjens, H., Zhang, D., Lu, Q., Weber, I., & Zhu, L. (2025). *RAGOps: Operating and Managing Retrieval-Augmented Generation Pipelines* (Version 1). arXiv. https://doi.org/10.48550/ARXIV.2506.03401