2026

Exposé zur Masterarbeit

Cloud-native Referenzarchitektur für GenAIOps mit Quality-Gate-Kontrollsystem zur lifecycle-integrierten Operationalisierung regulatorischer, technischer und strategischer Anforderungen – am Bespiel des EU AI ACT

MUSTAFA DEMIR
Matrikelnummer: 2009670

Studiengang: Digital Management & Transformation (M.Sc.)

Betreuer: **Prof. Dr. Christian Prinz**

SRH FERNHOCHSCHULE - The Mobile University | Stuttgart

Inhaltsverzeichnis

1.1 Einleitung *3*

1.2 Problemdimensionen *3*

1.3 Zielsetzung *5*

1.4 Forschungsfragen *6*

1.5 Forschungsmethodik *7*

1.6 Scope und Abgrenzung *8*

2.1 Motivation *9*

2.2 Unternehmensakzeptanz *10*

2.3 Vorläufiger Zeitplan *10*

Gliederung **12**

1 Kapitelübersicht *12*

2 Theoretische Grundlagen *12*

3 Forschungsdesign und Methodik *13*

4 Anforderungsanalyse *13*

5 Entwicklung der Referenzarchitektur *14*

6 Evaluation *15*

7-8 Diskussion und Fazit *15*

Literaturverzeichnis **16**

1.1 Einleitung

Die rasante Adaption generativer KI (GenAI) und Large Language Models (LLMs) stellt Unternehmen vor operative Herausforderungen, die über den Wirkungsbereich etablierter MLOps-Verfahren hinausgehen. Bestehende CI/CD-Pipelines decken die spezifischen Risiken stochastischer Modelle — etwa Halluzinationen, Promptabhängigkeit oder kontextabhängige Qualitätsschwankungen — nicht systematisch ab (Sinha et al., 2024). Zugleich fordert der EU AI Act (VO 2024/1689) für Hochrisiko-KI-Systeme eine lückenlose Nachweisführung entlang des gesamten Lebenszyklus, für die weder operativ integrierte Frameworks noch automatisierte Kontrollmechanismen existieren. Dieser Befund lässt sich entlang dreier interdependenter Problemdimensionen konkretisieren.

1.2 Problemdimensionen

PD1: Fragmentierung bestehender Operationalisierungsframeworks: Traditionelle MLOps-Ansätze wurden für diskriminative Modelle mit stabilen Datenpipelines konzipiert. Generative KI-Systeme unterscheiden sich fundamental durch probabilistisches Ausgabeverhalten, Promptabhängigkeit und erhöhte Anforderungen an Observability und Sicherheitsbewertung (Sinha et al., 2024, S. 1–2). Bestehende Frameworks adressieren typischerweise isolierte Lebenszyklusphasen - Training, Deployment oder Monitoring, ohne eine integrierte End-to-End-Governance zu ermöglichen (Wang et al., 2025, S. 1; Díaz-De-Arcaya et al., 2024, S. 3). Obwohl sich die Operationsparadigmen von MLOps über LLMOps zu GenAIOps evolutionär weiterentwickeln (Kreuzberger et al., 2023; Pahune & Akhtar, 2025; Tantithamthavorn et al., 2025), ist GenAIOps als operativer Rahmen bislang weder konzeptuell konsolidiert noch in eine standardisierte Enterprise-Referenzarchitektur überführt worden (Joshi, 2025, S. 8; Pahune & Akhtar, 2025, S. 23).

Lücke 1: Es fehlt eine integrierte Referenzarchitektur, die den GenAI-Lifecycle end-to-end abdeckt und phasenübergreifende Kontrollmechanismen ermöglicht.

PD2: Methodische Inadäquanz bestehender Qualitätssicherungsmechanismen: Etablierte Qualitätskontrollverfahren basieren auf deterministischen Metriken (Accuracy, F1-Score, AUC-ROC), die für stochastische, kontextabhängige GenAI-Outputs methodisch ungeeignet sind (Polyakovska, 2025, S. 2, 5). Diese Inadäquanz manifestiert sich in drei Defiziten: (1) fehlende standardisierte Evaluationsmetriken für GenAI-spezifische Risikodimensionen wie Halluzinationsraten oder Prompt-Injection-Vulnerabilities (Xu et al., 2025, S. 14), (2) unzureichende Observability-Infrastruktur zur

Erzeugung und Persistierung prüfbarer Evidenz[1] (Xu et al., 2025, S. 15; Polyakovska, 2025, S. 6–7), und (3) fehlende phasenübergreifende Orchestrierung von Qualitätskontrollpunkten mit definierten Übergabekriterien (Wang et al., 2025, S. 1–2). **Lücke 2:** Für generative KI-Systeme existieren keine formalisierten, automatisierbaren Kontrollpunkte (Quality Gates), die Phasenübergänge an prüfbare Qualitätskriterien und nachweisbare Evidenz binden.

PD3: Compliance-Operationalisierungslücke (EU AI Act): Der EU AI Act definiert für Hochrisiko-KI-Systeme verbindliche Anforderungen an Risikomanagement (Art. 9), Daten-Governance (Art. 10), Dokumentation (Art. 11), Protokollierung (Art. 12), Transparenz (Art. 13), menschliche Aufsicht (Art. 14) sowie Genauigkeit, Robustheit und Cybersicherheit (Art. 15) (Europäische Union, 2024, S. 56–61). Diese Normen sind jedoch als juristisch-normative Pflichten formuliert — sie liefern keine technische Übersetzung in maschinenprüfbare Controls und keine durchgängige Evidenzkette für Audits. In der Literatur wird hervorgehoben, dass eine konsistente Abbildung regulatorischer Anforderungen in operative, automatisiert verifizierbare Protokolle nicht existiert (Díaz-Rodríguez et al., 2023, S. 14) und die KI-Governance-Forschung als deutlich unterentwickelt beschrieben wird (Taeihagh, 2025, S. 2, 7). Zwar existieren erste Governance-Frameworks wie AIGA (Burns et al., 2025) und CERTAIN (Kovac et al., 2025), doch bleibt deren technische Operationalisierung als automatisierte Pipeline-Kontrolle offen — beide verbleiben auf konzeptioneller Ebene und adressieren primär klassische ML-Systeme.

Lücke 3: Ein systematischer Ansatz, der AI-Act-spezifische Pflichten konsistent in Policy-/Compliance-as-Code überführt und über den GenAI-Lifecycle als automatisierte Quality Gates orchestriert, ist in der bestehenden Literatur nicht dokumentiert.

Synthese und resultierende Forschungslücke: Die drei Problemdimensionen beschreiben eine kumulative Lücke: Bestehende Frameworks sind fragmentiert und decken den GenAI-Lifecycle nicht integriert ab (PD1). Formalisierte, automatisierbare Quality Gates, die der stochastischen Natur generativer Systeme methodisch gerecht werden, fehlen (PD2). Und eine systematische Übersetzung der EU-AI-Act-Anforderungen in maschinenprüfbare Policies mit skalierbarer Evidenzerzeugung ist nicht dokumentiert (PD3). Diese dreifache Lücke — **strukturell, methodisch, regulatorisch** — begründet den Bedarf an einer integrierten Enterprise-

[1] Selbst wenn teilweise Daten entstehen, werden sie nicht sicher und dauerhaft gespeichert, sodass eine spätere Überprüfung erschwert oder unmöglich ist.

Referenzarchitektur, die cloud-native GenAIOps-Praktiken mit automatisierten Quality Gates verbindet und die Anforderungen des EU AI Act als prüfbare Kontrollmechanismen in CI/CD/CT-Pipelines operationalisiert.

1.3 Zielsetzung

Ziel der Arbeit ist die Entwicklung einer cloud-nativen Referenzarchitektur für GenAIOps, die e, technische und strategische Anforderungen — unter besonderer Berücksichtigung des EU AI Act (VO 2024/1689) — durch ein lifecycle-integriertes Quality-Gate-Kontrollsystem systematisch operationalisiert. Die Architektur verfolgt den Ansatz **Accountability-by-Design**: Verantwortungsnachweisbarkeit wird nicht als nachgelagerter Dokumentationsprozess verstanden, sondern als technisch erzwungene Eigenschaft des Systems.

Das Artefakt umfasst vier Kernkomponenten: (S1) eine architekturelle Grundstruktur mit Schichten- und Komponentenmodell, (S2) ein Quality-Gate-Kontrollsystem als zentrales Designprinzip mit präventiven, detektiven und evidenzbasierten Gate-Typen, (S3) eine Pipeline-Integration in bestehende CI/CD/CT-Toolchains und (S4) eine Evidence- und Audit-Logik zur lückenlosen Nachweisführung. Der PoC demonstriert einen einzelnen, repräsentativen Deployment-Pfad (Model Registry → Pre-Deployment Gate → Staging → Post-Deployment Gate → Production) und deckt damit mindestens je ein Quality Gate der Dimensionen Compliance, Strategie und Technik ab. Der PoC demonstriert insbesondere die technische Durchsetzung (Enforcement): Bei Nichterfüllung definierter Gate-Kriterien wird ein Deployment automatisiert blockiert — die Architektur erzwingt Compliance, statt sie nur zu dokumentieren.

Die Architektur beansprucht dabei keine juristische Zertifizierung oder automatische Compliance-Garantie, sondern stellt eine technisch operationalisierbare Struktur zur Durchsetzung und auditierbaren Nachweisunterstützung regulatorischer Anforderungen bereit.

Die Architekturentwicklung wird durch fünf Design-Prinzipien geleitet:

- **DP1 – Compliance als kontrollierbarer Lifecycle-Prozess:** Normative Anforderungen werden nicht punktuell geprüft, sondern als durchgängiger, Gate-basierter Kontrollprozess über den gesamten GenAI-Lifecycle operationalisiert.
- **DP2 – Lückenlose Traceability-Kette:** Jede High-Risk-Anforderung wird in eine Policy (Policy-as-Code oder kontrollierbare Regel) übersetzt, die automatisch oder manuell Evidenz erzeugt, die auditierbar verknüpft ist (R → DP → Gate → Evidence).

- **DP3 – Gate-Template als Standardisierungseinheit:** Jedes Quality Gate wird durch ein einheitliches Template formalisiert (Trigger, Kriterien, Evidenzartefakte, Entscheidung, Verantwortlichkeit, Audit Trail, Waiver-Regelung).
- **DP4 – Trennung von Governance-Ebenen, integrierte Entscheidung:** Strategische, technische und Compliance-Gates werden getrennt modelliert, aber über gemeinsame Artefakte und Entscheidungslogik gekoppelt.
- **DP5 – Cloud-native Integrierbarkeit:** Das Kontrollsystem muss in bestehende cloud-native CI/CD/CT-Toolchains integrierbar sein, ohne proprietäre Abhängigkeiten zu erzeugen.

Die Nachvollziehbarkeit wird über eine durchgängige Traceability-Kette gesichert, die jede regulatorische Anforderung (R) über Design-Prinzipien (DP) zu konkreten Quality Gates und deren Evidenzartefakten zurückverfolgbar macht (R → DP → Gate → Evidence). Die formale Abbildung erfolgt in Kapitel 5 als Requirements-Traceability-Matrix.

Der wissenschaftliche Neuheitswert dieses Beitrages liegt in der formalisierten Integration bestehender Mechanismen (Rekonfiguration, Formalisierung und Kontextualisierung) für den spezifischen Kontext von High-Risk GenAI-Systemen. Der Erreichungsgrad wird anhand einer dreistufigen Evaluation überprüft: (a) Requirements-Coverage-Matrix, (b) PoC-Walkthrough und (c) Expert-Reviews (n≥4).

1.4 Forschungsfragen

Aus der Problemstellung und Zielsetzung werden drei Forschungsfragen abgeleitet, die den drei DSR-Zyklen (Relevance, Design, Rigor) nach Hevner et al. (2004) zugeordnet sind:

RQ1 (Relevance): Welche regulatorischen, technischen und strategischen Anforderungen sind für eine verantwortungsnachweisbare Gestaltung von GenAI-Systemen im Enterprise-Kontext relevant und operationalisierbar?

RQ2 (Design): Wie kann eine Referenzarchitektur für GenAIOps gestaltet werden, die die erhobenen Anforderungen durch ein lifecycle-integriertes Quality-Gate-Kontrollsystem systematisch operationalisiert? (Nur Deployment- und Inference-Zyklus)

RQ3 (Rigor): Inwiefern ist die entwickelte Referenzarchitektur geeignet, regulatorische Anforderungen technisch durchzusetzen und auditierbar nachweisbar zu machen?

Die Beantwortung von RQ3 erfolgt über ein dreistufiges Evaluationsdesign: (1) eine Coverage-Matrix, die prüft, ob alle identifizierten Anforderungen durch mindestens ein

Quality Gate adressiert werden, (2) einen Szenario-Walkthrough, der die Machbarkeit der Architektur anhand eines exemplarischen GenAI-Deployment-Zyklus demonstriert, sowie (3) ein Expert-Assessment (n≥4), das die Praxistauglichkeit je Gate-Dimension (Compliance, Strategie, Technik) bewertet.

1.5 Forschungsmethodik

Die Arbeit folgt dem Paradigma der **Design Science Research (DSR)** und kombiniert drei methodische Rahmenwerke:

(1) Das **Information Systems Research Framework** nach Hevner et al. (2004) bildet die Meta-Ebene. Es strukturiert die Arbeit über die drei Zyklen Relevance (Problemkontext), Design (Artefaktkonstruktion) und Rigor (Wissensbasis) und definiert sieben Leitlinien (Guidelines G1–G7), deren Einhaltung die wissenschaftliche Qualität des Artefakts sichert.

(2) Die **Design Science Research Methodology (DSRM)** nach Peffers et al. (2007) liefert die Prozessebene. Der sechsstufige Prozess (Problem Identification, Objectives, Design & Development, Demonstration, Evaluation, Communication) wird problem-centered durchlaufen und auf die Kapitelstruktur der Arbeit abgebildet.

(3) Das **DSR Grid** nach vom Brocke und Maedche (2019) dient als Strukturierungswerkzeug. Es operationalisiert die Forschungsplanung entlang von sechs Dimensionen (Problem/Solution/Evaluation × Relevance/Rigor) und sichert die systematische Abdeckung aller DSR-relevanten Aspekte.

Der **Artefakttyp** umfasst nach Hevner et al. (2004): Model (Architektur), Method (Gate-Systematik und Traceability) und Instantiation (Proof-of-Concept). Die Arbeit durchläuft zwei Iterationen: Iteration 1 entwickelt das konzeptuelle Architekturmodell und die Gate-Systematik; Iteration 2 instanziiert die Architektur als Azure-basierten Proof-of-Concept und verfeinert das Design reflektiv auf Basis der Demonstrationsergebnisse. Die zweite Iteration dient somit nicht ausschließlich der technischen Umsetzung, sondern der systematischen Überprüfung und Weiterentwicklung des Artefakts. Identifizierte Inkonsistenzen, Durchsetzungsgrenzen oder Traceability-Brüche führen zu gezielten Anpassungen der Gate-Spezifikationen, Policy-Zuordnungen oder Evidenzmechanismen.

Die **Evaluation** folgt einem dreistufigen Design:

(a) **Requirements-Coverage-Matrix:** Systematischer Abgleich der Architekturkomponenten mit den erhobenen Anforderungen (R1–Rn) zur Prüfung der Vollständigkeit.

(b) **PoC-Walkthrough:** Technische Demonstration der Durchsetzung (Policy-Enforcement) anhand ausgewählter Szenarien im Azure-Stack. Dabei werden sowohl positive als auch negative Gate-Durchläufe berücksichtigt, um zu prüfen, ob bei Nichterfüllung definierter Kriterien ein Deployment technisch blockiert wird. Ergänzend wird die Integrität der erzeugten Evidenzartefakte überprüft, insbesondere hinsichtlich Persistierung, Versionierung und Unveränderlichkeit.

(c) **Expert-Reviews (n≥4):** Leitfadengestützte Interviews mit Domänenexperten aus den Bereichen MLOps/LLMOps/GenAIOps, Cloud-Architektur und KI-Governance zur Bewertung der Praxistauglichkeit und Audit-Readiness.

1.6 Scope und Abgrenzung

Die Referenzarchitektur wird als generisches Modell entwickelt, das branchenunabhängig und auf domänenspezifische Anforderungen (im PoC exemplarisch: Healthcare/FDA 21 CFR Part 11) anwendbar ist. Die prototypische Instanziierung (Proof-of-Concept) erfolgt in der Healthcare-Domäne am Beispiel eines Ambient AI Scribe — eines generativen KI-Systems zur automatisierten Transkription und Zusammenfassung medizinischer Gespräche (Healthcare als exemplarischer Anwendungsfall für die PoC-Validierung, nicht als Architektur-Scope).
Dieses Szenario eignet sich aus mehreren Gründen: (1) Es handelt sich um ein Hochrisiko-KI-System gemäß EU AI Act Annex III (medizinische Diagnostik und Entscheidungsunterstützung), (2) es erfordert die Verarbeitung sensibler Gesundheitsdaten unter DSGVO- und KI-Regulierungsvorgaben, (3) die Qualitätsanforderungen an generative Outputs (Halluzinationsfreiheit, klinische Präzision) sind besonders hoch und (4) die Nachweispflichten gegenüber Aufsichtsbehörden sind umfassend.

Der PoC wird auf dem Microsoft Azure Stack implementiert und nutzt Azure Kubernetes Service (AKS), Azure OpenAI Service, GitOps-Controller wie ArgoCD, Open Policy Agent (OPA/Rego) sowie Azure Monitor und Blob Storage (immutable) für die Evidence-Persistierung. Der Evidence Store folgt einem hybriden Ansatz: Unstrukturierte Artefakte (Model Cards, Evaluierungsreports) werden im Blob Storage abgelegt, während die strukturierten Metadaten der Quality-Gate-Durchläufe in einer relationalen Datenbank

persistiert werden. Diese Trennung ermöglicht einerseits performantes Compliance-Reporting über indizierte Abfragen und stellt andererseits durch datenbankgestützte Schutzmechanismen (Immutability-Constraints, View-basierte Zugriffskontrolle) die Manipulationssicherheit der Audit-Nachweise sicher — eine zentrale Voraussetzung im Healthcare-Kontext, in dem medizinische Payload und regulatorische Telemetrie strikt getrennt werden müssen (DSGVO Art. 9). Die Architektur selbst bleibt cloud-provider-agnostisch (DP5: Cloud-native Integrierbarkeit).
Die Wahl von Microsoft Azure als Cloud-Plattform erfolgt unter Berücksichtigung der EU-Datenresidenz-Optionen (Azure EU Data Boundary). Der potenzielle Konflikt zwischen US CLOUD Act und EU AI Act Art. 2 Abs. 1 (territorialer Anwendungsbereich) wird als Limitation dokumentiert und in der Diskussion (Kapitel 7) adressiert. (STACKIT?)

Abgrenzung: Die Arbeit entwickelt keine eigenständigen KI-Modelle, sondern fokussiert auf die architekturelle Steuerung und Qualitätssicherung bestehender GenAI-Dienste. Explizit außerhalb des Scope liegen: LLM-Training und Fine-Tuning, eigenständige Modellentwicklung (Data Science) sowie die Optimierung von Data-Engineering-Pipelines. Ethische Fragestellungen werden nur insoweit adressiert, als sie sich in technisch operationalisierbare Anforderungen übersetzen lassen. Die rechtliche Analyse beschränkt sich auf die für High-Risk-Systeme relevanten Artikel des EU AI Act (Art. 9–15) und erhebt keinen Anspruch auf juristische Vollständigkeit.

2.1 Motivation

Die Themenwahl ist sowohl durch die berufliche Spezialisierung als auch durch ein weiterführendes Forschungsinteresse motiviert. Zurzeit absolviere ich parallel zur Masterarbeit eine zertifizierte Vollzeit-Weiterbildung zum Cloud Architect (810 UE, AZAV-zertifiziert) mit Schwerpunkt auf Kubernetes, Infrastructure-as-Code und CI/CD-Pipelines, die die technische Basis der Arbeit unmittelbar ergänzt. Im Masterstudium bildete Künstliche Intelligenz das Vertiefungsfach (Note: 1,0), ergänzt durch Praxisprojekte im Bereich KI-gestütztes Requirements Engineering und cloud-native Architekturentwicklung (jeweils Note: 1,0). Darüber hinaus umfasst die Weiterbildung ein verpflichtendes Praxisprojekt, in dem ich eine Cloudarchitektur entwickeln werde. Die dabei verfügbare fachliche Begleitung durch erfahrene Cloud-Architekten ermöglicht ein Practitioner Review, das die leitfadengestützten Experteninterviews als zusätzliche Evaluationsperspektive ergänzt. Die berufliche Erfahrung im Automotive-Sektor — unter anderem als Projektleiter bei Mercedes-AMG und als strategischer Produktmanager bei der Mercedes-Benz AG mit Verantwortung für Schnittstellenmanagement, Datenintegration und Governance-Strukturen — hat den Bedarf an integrierten,

regulatorisch konformen Betriebsarchitekturen für KI-Systeme aus der Praxis heraus sichtbar gemacht.

Über das unmittelbare Berufsziel als AI & Cloud Solution Architect hinaus verfolge ich das Ziel einer Promotion im Bereich KI- und Innovationsmanagement. Die vorliegende Arbeit soll dafür eine methodisch und inhaltlich tragfähige Grundlage schaffen. Darüber hinaus ist die Überzeugung leitend, dass die technologische und regulatorische Souveränität Europas — insbesondere im Bereich Cloud-Infrastruktur und KI-Governance — eine eigenständige architektonische Antwort erfordert, zu der diese Arbeit einen konzeptionellen Beitrag leisten möchte.

2.2 Unternehmensakzeptanz

Vorerst wird die Arbeit als rein akademisches Forschungsprojekt ohne festen Praxispartner durchgeführt. Dies ist im Rahmen einer Design-Science-Research-Arbeit methodisch unproblematisch, da das zentrale Artefakt — eine generalisierbare Referenzarchitektur — nicht an einen spezifischen Unternehmenskontext gebunden ist, sondern als übertragbares Designwissen konzipiert wird (Hevner et al., 2004, S. 80). Die Evaluation stützt sich auf leitfadengestützte Experteninterviews mit Domänenexperten aus Wissenschaft und Praxis, deren Zugang sowohl über das akademische und berufliche Netzwerk als auch über die Fortbildung gesichert ist. Für die prototypische Implementierung (PoC) stehen studentische Cloud-Ressourcen (Microsoft Azure) sowie Open-Source-Tooling zur Verfügung. Eine optionale Kooperation mit einem Startup zur Validierung des Ambient-AI-Scribe-Szenarios (oder eines ähnlichen Use Case) wird derzeit geprüft, ist für die Durchführbarkeit der Arbeit jedoch nicht erforderlich.

2.3 Vorläufiger Zeitplan

Die Bearbeitungsdauer beträgt 16 Wochen. Der Zeitplan orientiert sich an den DSRM-Schritten und der Kapitelstruktur:

Woche	Phase	Aktivitäten	Ergebnis
1–2	Grundlagen & Methodik (bereits erledigt)	DSR-Rahmen erarbeiten, Kapitel 2–3 schreiben	Kap. 2–3 (Entwurf)
2–4	Anforderungsanalyse	EU AI Act Art. 9–15, Literaturanalyse, R-Katalog erstellen	Kap. 4, R1–Rn
4–6	Architekturentwurf (Iter. 1)	DP1–DP5 anwenden, S1–S4 spezifizieren, Gate-Katalog	Kap. 5.1–5.5 (Konzept)

6–9	PoC-Entwicklung (Iter. 2)	Azure-Instanziierung, Pipeline-Setup, Gate-Implementierung	Kap. 5.6 (PoC)
9–11	Evaluation	Coverage-Matrix, PoC-Walkthrough, Expert-Interviews (n≥4)	Kap. 6
11–13	Diskussion & Synthese	Ergebnisinterpretation, Beiträge, Limitationen	Kap. 7
13–15	Fertigstellung	Kap. 1+8 schreiben, Gesamtrevision, Formatierung	Gesamtdokument
15–16	Puffer & Abgabe	Korrekturlesen, Druck, Abgabe	Finale Abgabe

Tabelle 7: Vorläufiger Zeitplan (16 Wochen)

Gliederung

1 Kapitelübersicht

Die Arbeit gliedert sich in acht Kapitel, die dem DSRM-Prozess nach Peffers et al. (2007) folgen und den drei DSR-Zyklen nach Hevner et al. (2004) zugeordnet sind.

Kap.	Inhalt	DSRM-Schritt	DSR-Cycle
1	Einleitung (PD1–PD3, Zielsetzung, Forschungsfragen)	1 Problem ID	—
2	Theoretische Grundlagen (GenAIOps, EU AI Act, Ref.Arch., DSR)	2 Objectives	—
3	Forschungsdesign und Methodik (DSR-Rahmen, Operationalisierung)	2 Objectives	Meta
4	Anforderungsanalyse (R1–Rn, MUSS/SOLL)	2→3 Design	Relevance
5	Entwicklung der Referenzarchitektur (DP1–DP5, S1–S4, PoC)	3 Design + 4 Demo	Design
6	Evaluation (Coverage, PoC-Walkthrough, Expert-Reviews)	5 Evaluation	Rigor
7	Diskussion (Beitrag, Limitationen, Implikationen)	6 Communication	—
8	Fazit und Ausblick	6 Communication	—

Tabelle 1: Kapitelstruktur mit DSRM- und DSR-Cycle-Zuordnung

2 Theoretische Grundlagen

Kapitel 2 legt die theoretische Basis in vier Bereichen:

GenAIOps, LLMOps und MLOps: Definition, Abgrenzung und Lifecycle-Modelle generativer KI-Systeme. Einordnung bestehender MLOps-Frameworks und deren Limitationen für GenAI-spezifische Anforderungen (Halluzinationskontrolle, Prompt-Management, Retrieval-Augmented Generation).

EU AI Act und regulatorischer Rahmen: Systematische Aufarbeitung der für Hochrisiko-KI-Systeme relevanten Anforderungen (Art. 9–15), ergänzt durch ISO 42001:2023 als komplementäres Managementsystem-Framework. EU AI Act und regulatorischer Rahmen: Systematische Aufarbeitung der für Hochrisiko-KI-Systeme relevanten Anforderungen (Art. 9–15); theoretische Fundierung der Gate-

Taxonomie (strategisch / technisch / Compliance) auf Basis des NIST AI RMF (2023)

Referenzarchitekturen: Theoretische Fundierung des Artefakttyps nach Angelov et al. und Winter und Fischer, einschließlich Abstraktionsebenen und Gestaltungskriterien.

Design Science Research: Darstellung der drei verwendeten Rahmenwerke (Hevner et al., Peffers et al., vom Brocke und Maedche) als Grundlage für Kapitel 3.

3 Forschungsdesign und Methodik

Kapitel 3 operationalisiert den DSR-Ansatz in acht Abschnitten (zu 90% abgeschlossen)

Abschnitt	Inhalt
3.1 DSR als Forschungsrahmen	Behavioral vs. Design Science, Begründung der Paradigmenwahl, Hevner 7 Guidelines
3.2 Methodischer Rahmen und Vorgehensmodell	Hevner (3 Zyklen), Peffers (DSRM, 6 Schritte), vom Brocke (DSR Grid)
3.3 Operationalisierung des DSR-Prozesses	Peffers-Mapping auf Kapitelstruktur, Iterationslogik (2 Iterationen)
3.4 Artefaktdefinition, Scope und Abgrenzung	Primärartefakt, Designprinzip, S1–S4, Instanziierungsstrategie
3.5 Anforderungserhebung und -analyse	Methodik der R-Katalog-Erstellung (Literatur + Regulatorik + Experten)
3.6 Traceability-Ansatz	RQ → R → DP → Gate → Evidence, methodische Begründung
3.7 Evaluationsdesign	3-stufig, Kriterien pro Gate-Dimension
3.8 Interviewdesign und Auswertung	Expertenauswahl, Leitfaden, Gütekriterien

Tabelle 2: Gliederung Kapitel 3 – Forschungsdesign und Methodik

4 Anforderungsanalyse

Kapitel 4 beantwortet RQ1 und bildet den Relevance-Cycle ab. Die Anforderungserhebung erfolgt durch systematische Analyse der beiden Quellen: (1) EU AI Act Art. 9–15 und Annex III/IV, (2) einschlägige Literatur zu MLOps, GenAIOps und KI-Governance. Das Ergebnis ist ein Anforderungskatalog (R1–Rn) mit MUSS/SOLL-Priorisierung, der als Input für die Architekturentwicklung dient.

Abschnitt	Inhalt
4.1 Vorgehen der Anforderungserhebung	Methodik und Quellenauswahl
4.2 Regulatorische Anforderungen (EU AI Act)	Art. 9–15, Annex III/IV, Anforderungsableitung
4.3 Technische Anforderungen (GenAIOps)	Pipeline-Anforderungen, GenAI-spezifische Metriken
4.4 Organisatorische Anforderungen	Governance-Strukturen, Rollenmodell
4.5 Anforderungskatalog (R1–Rn)	Konsolidierung, MUSS/SOLL-Priorisierung, Traceability

Tabelle 3: Gliederung Kapitel 4 – Anforderungsanalyse

5 Entwicklung der Referenzarchitektur

Kapitel 5 beantwortet RQ2 und bildet den Design-Cycle ab. Die Architekturentwicklung folgt den fünf Design-Prinzipien (DP1–DP5) und strukturiert das Artefakt in vier Säulen (S1–S4):

Abschnitt	Inhalt	Säule
5.1 Überblick und Designprinzipien	DP1–DP5, Architekturübersicht, Entwurfsentscheidungen	—
5.2 Architekturelle Struktur	Schichten- und Komponentenmodell, IaC-Integration	S1
5.3 Quality-Gate-Kontrollsystem	Gate-Taxonomie, Gate-Template, Lifecycle-Integration	S2 (USP)
5.3.1 Gate-Taxonomie und Lifecycle-Zuordnung	Strategische, technische, Compliance-Gates pro Phase	
5.3.2 Gate-Spezifikation und Template	Trigger, Kriterien, Evidence, Decision, Owner, Audit Trail, Waiver	
5.3.3 Compliance-Mapping	Art. 9–15 → Policies → Gates → Evidence	
5.4 Pipeline-Integration	CI/CD/CT-Einbettung, GitOps, Signierung	S3
5.4.1 CI/CD-Pipeline-Architektur	GitOps-Controller wie ArgoCD, Stage-Gates, automatisierte Prüfungen	
5.4.2 Policy-as-Code Integration	OPA/Rego, Policy-Bundles, Entscheidungsprotokollierung	

5.5 Evidence- und Audit-Logik	Evidence Store, Immutability, Audit-Readiness	S4 (USP)
5.5.1 Evidence-Persistierung	Immutable Storage, Versionierung, Retention	
5.5.2 Audit-Trail und Nachweiskette	Traceability: R → DP → Gate → Evidence	
5.6 Prototypische Instanziierung (PoC)	Azure-Stack, Healthcare-Szenario, 2. Iteration	Alle

Tabelle 4: Gliederung Kapitel 5 – Entwicklung der Referenzarchitektur

6 Evaluation

Kapitel 6 beantwortet RQ3 und bildet den Rigor-Cycle ab. Die Evaluation folgt einem dreistufigen Design, das Vollständigkeit, technische Durchsetzung, Evidenzintegrität und Praxistauglichkeit des Artefakts prüft:

Abschnitt	Inhalt	Evaluationsstufe
6.1 Evaluationsrahmen und Kriterien	Übersicht Evaluationsdesign, Kriterien pro Gate-Dimension	—
6.2 Requirements-Coverage-Matrix	R1–Rn → Architekturkomponenten, Vollständigkeitsprüfung	(a) Coverage
6.3 PoC-Walkthrough	Szenarien-basierte Demonstration, Evidenzgenerierung, Gate-Durchläufe	(b) Walkthrough
6.4 Expert-Reviews	Leitfadeninterviews (n≥4), qualitative Auswertung	(c) Expert
6.5 Synthese und Bewertung	Triangulation der Ergebnisse, Stärken/Schwächen/Anpassungsbedarfe	Gesamt

Tabelle 5: Gliederung Kapitel 6 – Evaluation

7-8 Diskussion und Fazit

Kapitel 7 diskutiert den wissenschaftlichen Beitrag (formalisierte Integration: Rekonfiguration, Formalisierung, Kontextualisierung), ordnet die Ergebnisse in die Knowledge Base ein (Hevner Guideline G7), identifiziert Limitationen und formuliert Implikationen für Praxis und Forschung. Kapitel 8 fasst die Ergebnisse zusammen, bewertet den Zielerreichungsgrad und gibt einen Ausblick auf weiterführende Forschung.

Literaturverzeichnis

Alugunuri, N. (2022). Policy-Driven Infrastructure Automation for Microservices: A Unified Framework Combining Infrastructure as Code and Policy as Code in Cloud-Native Environments. *International Journal on Science and Technology*, 13(3), 5966. https://doi.org/10.71097/IJSAT.v13.i3.5966

Blancato, F. G. (2024). The cloud sovereignty nexus: How the European Union seeks to reverse strategic dependencies in its digital ecosystem. *Policy & Internet*, 16(1), 12–30. https://doi.org/10.1002/poi3.358

Burns, F., Edelberg, J., Kuivanen, P., Tuomi, E., Ylimaa, J., & Tikanmäki, I. (2025). AI Governance: Achieving EU AI Act Compliance in the Dynamo Project. In *The Proceedings of the 24th European Conference on Cyber Warfare and Security, ECCWS 2025* (S. 875–878). https://doi.org/10.34190/eccws.24.1.3378

Díaz-De-Arcaya, J., Torre-Bastida, A. I., Zárate, G., Miñón, R., & Almeida, A. (2024). LLMOps: A State of the Art and Comprehensive Overview. arXiv preprint, arXiv:2407.11657.

Díaz-De-Arcaya, J., López-De-Armentia, J., Miñón, R., Ojanguren, I. L., & Torre-Bastida, A. I. (2024). Large Language Model Operations (LLMOps): Definition, Challenges, and Lifecycle Management. In *2024 9th International Conference on Smart and Sustainable Technologies (SpliTech)* (S. 1–6). IEEE. https://doi.org/10.23919/SpliTech61897.2024.10612341

Di Martino, B., & Esposito, A. (2022). An Overview of Reference Architectures for Cloud Continuum Interoperability. *2022 Cloud Continuum*, 1–5. https://doi.org/10.1109/CloudContinuum57429.2022.00009

Europäische Union. (2024). Verordnung (EU) 2024/1689 des Europäischen Parlaments und des Rates vom 13. Juni 2024 zur Festlegung harmonisierter Vorschriften für künstliche Intelligenz (Verordnung über künstliche Intelligenz). *Amtsblatt der Europäischen Union*, L 2024/1689.

Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75–105. https://doi.org/10.2307/25148625

Joshi, S. (2025). LLMOps, AgentOps, and MLOps for Generative AI: A Comprehensive Review. *International Journal of Computer Applications Technology and Research*. https://doi.org/10.7753/IJCATR1407.1001

Kreuzberger, D., Kühl, N., & Hirschl, S. (2023). Machine Learning Operations (MLOps): Overview, Definition, and Architecture. *IEEE Access*, 11, 31866–31879. https://doi.org/10.1109/ACCESS.2023.3262138

Krishnamurthy, D., & Neelanath, V. (2025). Establishing a Robust LLMOps Framework for Intelligent Automation: Strategies and Best Practices. *2025 Emerging Technologies for Intelligent Systems (ETIS)*, 1–5. https://doi.org/10.1109/ETIS64005.2025.10961869

Kovac, F., Neumaier, S., Pahi, T., Priebe, T., Rodrigues, R., Christodoulou, D., Cordy, M., Kubler, S., Kordia, A., Pitsiladis, G., Soldatos, J., & Zervoudakis, P. (2025). Towards a

Framework for Supporting the Ethical and Regulatory Certification of AI Systems. arXiv preprint. https://doi.org/10.48550/ARXIV.2510.00084

Kumara, I., Pecorelli, F., Catolino, G., Kazman, R., Tamburri, D. A., & Van Den Heuvel, W.-J. (2023). Architecting MLOps in the Cloud: From Theory to Practice. *2023 IEEE 20th International Conference on Software Architecture Companion (ICSA-C)*, 333–335. https://doi.org/10.1109/ICSA-C57050.2023.00076

Mahr, F., Angeli, G., Sindel, T., Schmidt, K., & Franke, J. (2024). A Reference Architecture for Deploying Large Language Models in Industrial Environments. *2024 IEEE 30th International Symposium for Design and Technology in Electronic Packaging (SIITME)*, 19–23. https://doi.org/10.1109/SIITME63973.2024.10814877

March, S. T., & Smith, G. F. (1995). Design and natural science research on information technology. *Decision Support Systems*, 15(4), 251–266. https://doi.org/10.1016/0167-9236(94)00041-2

Mazon-Olivo, B., & Pan, A. (2022). Internet of Things: State-of-the-art, Computing Paradigms and Reference Architectures. *IEEE Latin America Transactions*, 20(1), 49–63. https://doi.org/10.1109/TLA.2022.9662173

National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)*. U.S. Department of Commerce. https://doi.org/10.6028/NIST.AI.100-1

Novelli, C., Casolari, F., Hacker, P., Spedicato, G., & Floridi, L. (2024). Generative AI in EU law: Liability, privacy, intellectual property, and cybersecurity. *Computer Law & Security Review*, 55, 106066. https://doi.org/10.1016/j.clsr.2024.106066

Pahune, S., & Akhtar, Z. (2025). Transitioning from MLOps to LLMOps: Navigating the Unique Challenges of Large Language Models. *Information*, 16(2), 87. https://doi.org/10.3390/info16020087

Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45–77. https://doi.org/10.2753/MIS0742-1222240302

Polyakovska, N. O. (2025). Towards a Practical Framework for LLMOps: Understanding and Building Operational Excellence for Large Language Models. *Computer-Integrated Technologies: Education, Science, Production*, 58, 100–107. https://doi.org/10.36910/6775-2524-0560-2025-58-14

Pourmajidi, W., Zhang, L., Steinbacher, J., Erwin, T., & Miranskyy, A. (2025). A Reference Architecture for Governance of Cloud Native Applications. *IEEE Transactions on Cloud Computing*, 13(3), 935–952. https://doi.org/10.1109/TCC.2025.3578557

Sinan, M., Shahin, M., & Gondal, I. (2025). Integrating Security Controls in DevSecOps: Challenges, Solutions, and Future Research Directions. *Journal of Software: Evolution and Process*, 37, e70029. https://doi.org/10.1002/smr.70029

Sinha, M., Menon, S., & Sagar, R. (2024). LLMOps: Definitions, Framework and Best Practices. In *2024 International Conference on Electrical, Computer and Energy*

Technologies (ICECET) (S. 1–6). IEEE. https://doi.org/10.1109/ICECET61485.2024.10698359

Sovrano, F., Hine, E., Anzolut, S., & Bacchelli, A. (2025). Simplifying software compliance: AI technologies in drafting technical documentation for the AI Act. *Empirical Software Engineering*, 30, 91. https://doi.org/10.1007/s10664-025-10620-y

Stone, J., Patel, R., Ghiasi, F., Mittal, S., & Rahimi, S. (2025). Navigating MLOps: Insights into Maturity, Lifecycle, Tools, and Careers. *2025 IEEE Conference on Artificial Intelligence (CAI)*, 643–650. https://doi.org/10.1109/CAI64502.2025.00118

Taeihagh, A. (2025). Governance of Generative AI. *Policy and Society*, 44(1), 1–22. https://doi.org/10.1093/polsoc/puaf001

Tantithamthavorn, C. K., Palomba, F., Khomh, F., & Chua, J. J. (2025). MLOps, LLMOps, FMOps, and Beyond. *IEEE Software*, 42(1), 26–32. https://doi.org/10.1109/MS.2024.3477014

vom Brocke, J., & Maedche, A. (2019). The DSR grid: Six core dimensions for effectively planning and communicating design science research projects. *Electronic Markets*, 29(3), 379–385. https://doi.org/10.1007/s12525-019-00358-7

Wang, K., Zhang, G., Zhou, Z., Wu, J., Yu, M., Zhao, S., Yin, C., Fu, J., Yan, Y., Luo, H., Lin, L., Xu, Z., Lu, H., Cao, X., Zhou, X., Jin, W., Meng, F., Xu, S., Mao, J., … Liu, Y. (2025). A Comprehensive Survey in LLM(-Agent) Full Stack Safety: Data, Training and Deployment (Version 4). arXiv. https://doi.org/10.48550/ARXIV.2504.15585

Xu, X., Weytjens, H., Zhang, D., Lu, Q., Weber, I., & Zhu, L. (2025). RAGOps: Operating and Managing Retrieval-Augmented Generation Pipelines (Version 1). arXiv. https://doi.org/10.48550/ARXIV.2506.03401

Angelov, S., Grefen, P., & Greefhorst, D. (2012). A framework for analysis and design of software reference architectures. *Information and Software Technology*, 54(4), 417–431. https://doi.org/10.1016/j.infsof.2011.11.009

International Organization for Standardization. (2023). *ISO/IEC 42001:2023 – Information technology – Artificial intelligence – Management system*. ISO.

Mayring, P. (2015). *Qualitative Inhaltsanalyse: Grundlagen und Techniken* (12. Aufl.). Beltz.

Winter, R., & Fischer, R. (2006). Essential Layers, Artifacts, and Dependencies of Enterprise Architecture. *2006 10th IEEE International Enterprise Distributed Object Computing Conference Workshops (EDOCW'06)*, 30–30. https://doi.org/10.1109/EDOCW.2006.33